

VK-RMD: 基于视觉关键点替代 RGB 与 Full-to-Subset Guidance 的缺失模态多模态人体感知

作者姓名
Eagle

摘要

多模态 AR 平均值结论。

关键词: 多模态感知, 人体姿态估计, 人体活动识别, 缺失模态, 视觉关键点, Full-to-Subset Guidance, 低视觉暴露。

1 引言

多模态部署中的模态缺失。一个在完整模态集合上训练和测试的模型, 并不自然适用于任意子集输入。直接让模型在缺失模态下训练虽然可行, 但容易缺少完整模态感知行为的约束。因此, 本文提出 Full-to-Subset Guidance (FSG): 教师模型固定使用完整模态集合学习完整感知行为, 学生模型在随机采样的可用模态子集上训练, 并在缺失条件下学习逼近教师的输出、结构 token 与融合行为。FSG 与传统知识蒸馏不同: 传统蒸馏通常强调大模型到小模型的能力压缩, 而本文强调完整模态到缺失模态子集的条件迁移, 即 teacher 和 student 的主要差异不是参数规模, 而是输入可用性。

本文提出 VK-RMD, 围绕任务监督的 body-latent token 空间; FSG 通过完整模态教师约束随机缺失学生, 使学生在不同传感器可用条件下仍能完成 HPE/HAR。Student-VK 与 Student-NV 的缺失模态结果直接服务 FSG 主线, 是正文核心结果; 可靠性腐蚀、body-latent 诊断和 Super-Teacher 探索用于解释机制边界和部署条件。

本文主要贡献如下:

- 从身份暴露角度重新定位 VK
- 提出
- 在 H

2 相关工作

2.1 RGB 暴露风险与 VK 替代

基于

2.2 多模态 HPE 与 HAR

HPE。

2.3 缺失模态学习

缺失

2.4 Full-to-Subset Guidance 与传统蒸馏

传统知识蒸

2.5 与最接近范式的区别

最向各

3 VK-RMD 框架

3.1 问题定义

令 $\mathcal{M}_p = \{VK, D, L, R, W\}$ 表示 HPE 模态集合, 其中 D, L, R 和 W 分别表示 Depth、LiDAR、mmWave 和 WiFi-CSI。令 $\mathcal{M}_a = \{VK, D, L, R\}$ 表示 HAR 模态集合。对每个样本, 只有非空子集 $\mathcal{S} \subseteq \mathcal{M}$ 可能可用。学生模型接收 $\mathbf{x}_\mathcal{S} = \{\mathbf{x}_m : m \in \mathcal{S}\}$, 并预测 3D 姿态 $\hat{\mathbf{Y}}$ 或动作概率向量 $\hat{\mathbf{p}}$ 。

对于

3.2 VK 介导的 Body-Latent Tokenization

VK 被表示为 17 关节人体图, 而不是普通坐标数组。令 $\mathbf{x}_v \in \mathbb{R}^{17 \times 2}$ 表示 VK 输入。本文将其看作 $G_v = (V, E, X)$, 其中 V 包含语义关节身份, E 是骨架拓扑, X 是坐标观测。VK 编码器归一化坐标, 加入坐标、位置和关节身份嵌入, 并在骨架图上传播信息:

$$\mathbf{J}_v = \phi_c(\tilde{\mathbf{x}}_v) + \phi_p(2\tilde{\mathbf{x}}_v - 1) + \mathbf{e}_{joint}, \quad (1)$$

$$\mathbf{J}_v^{(k+1)} = \text{BoneGraphMixer}(\mathbf{J}_v^{(k)}, A_{bone}), \quad (2)$$

$$\mathbf{Z}_v = P_v(\mathbf{J}_v) \in \mathbb{R}^{K \times D}. \quad (3)$$

对每个非 VK 模态 m , 模态专属 backbone 和可训练 projector 产生 body-latent token:

$$\mathbf{Z}_m = P_m(E_m(\mathbf{x}_m)) \in \mathbb{R}^{K \times D}. \quad (4)$$

因此, 原始空间不被直接对齐。WiFi-CSI 张量、LiDAR 点云、雷达点集和 VK 坐标首先被映射到共享 body-latent token 维度。本文使用 body-latent tokenization, 而不是严格语义对齐: 这种对应关系由样本级同步、共同 HPE/HAR 监督、模态嵌入和 VK 骨架拓扑诱导, 而不是被保证的几何配准。

对于可用子集 $\mathcal{S}$, 加入模态嵌入并拼接:

$$\mathbf{U}_\mathcal{S} = \text{Concat}_{m \in \mathcal{S}}(\mathbf{Z}_m + \mathbf{e}_m), \quad (5)$$

$$\mathbf{T}_\mathcal{S} = \text{TransformerEncoder}(\mathbf{U}_\mathcal{S}). \quad (6)$$

编码后的 token 被切分为模态块 $\{\mathbf{T}_m\}_{m \in \mathcal{S}}$ 。每个块产生模态级姿态或动作专家以及 log-variance 分数 s_m 。默认可靠性融合为

$$\alpha_m = \frac{\exp(-s_m/\tau)}{\sum_{j \in \mathcal{S}} \exp(-s_j/\tau)}. \quad (7)$$




图 1: VK-RMD 总体框架。本文主线由两部分组成: VK 替代原始 RGB 进入下游感知流程, 以降低身份外观暴露; FSG 使用完整模态教师约束随机缺失模态学生, 使学生在任意传感器子集下学习完整感知行为。非 RGB 传感器被映射到同一任务监督 body-token 空间, 可靠性融合用于辅助当前可用子集动态决策。

对于 HPE, 模态级姿态专家和残差融合 token 头组合为

$$\hat{\mathbf{Y}} = 0.5 \sum_{m \in \mathcal{S}} \alpha_m \hat{\mathbf{Y}}_m + 0.5 H_{res} \left(\sum_{m \in \mathcal{S}} \alpha_m \text{Pool}(\mathbf{T}_m) \right). \quad (8)$$

对于 HAR, 相同机制应用于 logits:

$$\hat{\mathbf{c}} = 0.5 \sum_{m \in \mathcal{S}} \alpha_m \hat{\mathbf{c}}_m + 0.5 H_{res} \left(\sum_{m \in \mathcal{S}} \alpha_m \text{Pool}(\mathbf{T}_m) \right). \quad (9)$$

权重 α_m 是学习得到的贡献代理, 不应解释为校准后的物理传感器可靠性。

3.3 两条主线: VK 替代 RGB 与 FSG 约束缺失模态

本文框架围绕两条主线组织。第一, VK 替代 RGB: 原始 RGB 提供强身体和上下文信息, 但会保留大量可恢复身份的外观线索; VK 将视觉输入压缩为关节级身体结构, 使下游模型在不消费原始 RGB 的条件下完成 HPE/HAR。第二, FSG 约束缺失模态: 完整模态教师学习所有传感器可用时的感知行为, 随机缺失学生学习在任意可用子集下逼近这种完整行为。可靠性融合和 body-token 表示是服务这两条主线的实现机制。

3.4 VK 锚定 Body-Tokenization

图 ?? 展示总体框架。原始视觉数据如果被使用, 也被隔离在上游 VK 提取阶段; 下游模型接收 VK 而不是原始 RGB。VK 被编码为关节级身体几何。其他模态使用各自编码器, 因为它们的原始形态异构: Depth 图像、点云、雷达点和 WiFi-CSI 序列无法在原始空间直接对齐。对模态 m , 特征被编码为

$$\mathbf{z}_m = P_m(E_m(\mathbf{x}_m)) + \mathbf{e}_m, \quad (10)$$

其中 E_m 是模态专属编码器, P_m 是投影到共享 body-token 维度的层, $\mathbf{e}_m$ 是模态嵌入。对齐因此发生在 body-token 空间, 并由共同 HPE/HAR 监督驱动。

3.5 子集条件缺失模态学习

训练时, 从子集分布中采样模态子集 $\mathcal{S}$, 只有 $\mathcal{S}$ 中的 token 被送入融合模块。这使每个子集成为一个有监督感知配置, 而不是简单的输入扰动。图 ?? 展示协议:




图 2: 缺失模态协议。训练阶段采样可用模态子集; 评估阶段覆盖所有非空组合: HPE 为 31 种, HAR 为 15 种。

训练阶段模拟模态缺失, 评估阶段穷尽测试所有模态组合。在该形式化中, 模态移除不仅是正则化, 而是模型必须解决的部署条件。

3.6 子集动态与可靠性融合

对可用 token $\{\mathbf{z}_m : m \in \mathcal{S}\}$, VK-RMD 预测归一化权重

$$\alpha_m = \frac{\exp(g(\mathbf{z}_m, \mathbf{e}_m))}{\sum_{k \in \mathcal{S}} \exp(g(\mathbf{z}_k, \mathbf{e}_k))}, \quad (11)$$

其中 $g(\cdot)$ 是学习得到的评分函数。融合表示为

$$\mathbf{z}_S = \sum_{m \in \mathcal{S}} \alpha_m \mathbf{z}_m. \quad (12)$$

输出头随后预测姿态或动作。 α_m 被解释为学习得到的模态贡献代理, 表示模型在给定子集下如何分配决策权重, 但不是校准的传感器健康度量。

3.7 Full-to-Subset Guidance 训练目标

FSG 是本文应对真实部署模态缺失的核心训练约束。教师使用完整模态集合 $\mathcal{M}$, 训练时不做随机模态丢弃, 因此它学习的是所有传感器可用时的完整感知行为:

$$\min_{\theta_T} \mathbb{E}_{(\mathbf{x}, y)} [\mathcal{L}^T(F_T(\{\mathbf{x}_m\}_{m \in \mathcal{M}}), y)]. \quad (13)$$

HPE 教师目标为

$$\mathcal{L}_{hpe}^T = \mathcal{L}_{pose}(\hat{\mathbf{Y}}_T, \mathbf{Y}) + \lambda_{bone} \mathcal{L}_{bone}(\hat{\mathbf{Y}}_T, \mathbf{Y}), \quad (14)$$

其中 bone 项保持骨架一致性。HAR 教师目标是交叉熵和可选不确定性项:

$$\mathcal{L}_{har}^T = CE(\hat{\mathbf{c}}_T, y) + \lambda_{unc} \mathcal{L}_{unc}. \quad (15)$$

教师训练后, 学生在随机采样子集上优化。此时 student 与 teacher 的差异不是模型大小, 而是输入条件: teacher 接收完整模态, student 只接收当前采样子集。因此, FSG 的目标是将完整模态行为约束到缺失模态学生, 而不是传统意义上的模型压缩:

$$\min_{\theta_S} \mathbb{E}_{(\mathbf{x}, y)} \mathbb{E}_{S \sim q(S)} [\mathcal{L}^S(F_S(\{\mathbf{x}_m\}_{m \in \mathcal{S}}), y, F_T(\{\mathbf{x}_m\}_{m \in \mathcal{M}}))]. \quad (16)$$

HPE 学生损失为

$$\mathcal{L}_{hpe}^S = \mathcal{L}_{gt} + \lambda_{out} \mathcal{L}_{out} + \lambda_{tok} \mathcal{L}_{tok} + \lambda_{bone} \mathcal{L}_{bone}^{KD} + \lambda_{rel} \mathcal{L}_{rel} + \lambda_{unc} \mathcal{L}_{unc}. \quad (17)$$

其中 $\mathcal{L}_{gt} = \text{SmoothL1}(\hat{\mathbf{Y}}_S, \mathbf{Y})$, $\mathcal{L}_{out} = \text{SmoothL1}(\hat{\mathbf{Y}}_S, \hat{\mathbf{Y}}_T)$, $\mathcal{L}_{tok} = \|\mathbf{z}_S - \mathbf{z}_T\|_2^2$, $\mathcal{L}_{bone}^{KD}$ 匹配教师与学生骨长, $\mathcal{L}_{rel}$ 将学生权重与限制并重归一化到可用子集上的教师权重对齐。HAR 学生损失为

$$\begin{aligned} \mathcal{L}_{har}^S = & CE(\hat{\mathbf{c}}_S, y) + \lambda_{kd} T^2 KL(\sigma(\hat{\mathbf{c}}_T/T) || \sigma(\hat{\mathbf{c}}_S/T)) \\ & + \lambda_{tok} \mathcal{L}_{tok} + \lambda_{rel} \mathcal{L}_{rel} + \lambda_{unc} \mathcal{L}_{unc}. \end{aligned} \quad (18)$$

因此, FSG 可以看作一种 full-modality-to-subset 约束。 $\mathcal{L}_{out}$ 约束输出行为, $\mathcal{L}_{tok}$ 约束中间结构表征, $\mathcal{L}_{rel}$ 约束模态贡献分配。它的作用不是证明 teacher 参数更强, 而是在训练期为缺失模态 student 提供完整模态行为参照。

4 实验设置

4.1 数据集与任务

实验采用 MMFi 风格多模态设置。HPE 使用 V、D、L、R 和 W; HAR 使用 V、D、L 和 R。随机划分是主要设置。跨场景和跨主体划分用于测试泛化。Student-VK 使用 V 和非 RGB 传感器, Student-NV 移除 V, 仅使用非视觉模态。所有正式学生推理均不输入原始 RGB, 因此实验首先检验“V 替代 RGB 后是否仍能完成 HPE/HAR”, 其次检验“FSG 是否能在传感器子集缺失时维持可用性”。

4.2 基线

本文使用与

4.3 指标

HPE 使

4.4 实现细节

主要报

5 结果与分析

5.1 与 X-Fi 原表项的直接对比

主要定量比

表 1: 与 X-Fi 原论文表项的 HPE 逐组合对比。MPJPE 和 PA-MPJPE 单位均为 mm，数值越低越好。绿色向下箭头表示相对 X-Fi 提升，红色向上箭头表示退化。VK-RMD 结果列用浅灰色标注。

模态	MPJPE↓			PA-MPJPE↓		
	X-Fi	VK-RMD	Δ	X-Fi	VK-RMD	Δ
V	93.9	92.7	↓ 1.2	60.3	42.6	↓ 17.7
D	101.8	53.9	↓ 47.9	48.4	35.6	↓ 12.8
L	167.1	140.1	↓ 27.0	103.2	93.5	↓ 9.7
R	127.4	115.0	↓ 12.4	69.8	58.1	↓ 11.7
W	225.6	222.1	↓ 3.5	105.3	110.2	↑ 4.9
V+D	86.1	51.7	↓ 34.4	48.1	34.3	↓ 13.8
V+L	93.0	73.2	↓ 19.8	59.7	41.9	↓ 17.8
V+R	88.8	68.9	↓ 19.9	57.3	38.9	↓ 18.4
V+W	93.0	88.1	↓ 4.9	59.5	42.3	↓ 17.2
D+L	102.5	53.0	↓ 49.5	48.4	35.4	↓ 13.0
D+R	98.0	52.3	↓ 45.7	47.3	34.6	↓ 12.7
D+W	101.8	53.5	↓ 48.3	48.1	35.5	↓ 12.6
L+R	109.8	97.5	↓ 12.3	63.4	55.1	↓ 8.3
L+W	159.5	134.2	↓ 25.3	102.7	93.2	↓ 9.5
R+W	117.2	108.5	↓ 8.7	62.7	57.3	↓ 5.4
V+D+L	84.8	51.1	↓ 33.7	48.2	34.2	↓ 14.0
V+D+R	83.4	50.5	↓ 32.9	47.3	33.5	↓ 13.8
V+D+W	85.3	51.6	↓ 33.7	48.1	34.3	↓ 13.8
V+L+R	88.4	66.1	↓ 22.3	57.2	38.8	↓ 18.4
V+L+W	93.0	70.7	↓ 22.3	59.7	41.8	↓ 17.9
V+R+W	88.5	66.7	↓ 21.8	57.1	38.8	↓ 18.3
D+L+R	96.0	51.9	↓ 44.1	47.3	34.5	↓ 12.8
D+L+W	102.0	52.9	↓ 49.1	48.1	35.4	↓ 12.7
D+R+W	97.0	52.1	↓ 44.9	47.1	34.6	↓ 12.5
L+R+W	107.4	94.2	↓ 13.2	63.1	55.1	↓ 8.0
V+D+L+R	83.5	50.2	↓ 33.3	47.6	33.4	↓ 14.2
V+D+L+W	86.0	51.0	↓ 35.0	48.2	34.2	↓ 14.0
V+D+R+W	84.0	50.4	↓ 33.6	47.6	33.5	↓ 14.1
V+L+R+W	88.6	64.2	↓ 24.4	57.1	38.8	↓ 18.3
D+L+R+W	97.6	51.8	↓ 45.8	47.4	34.5	↓ 12.9
V+D+L+R+W	83.7	50.2	↓ 33.5	47.6	33.5	↓ 14.1

表 2: 与 X-Fi 原论文表项的 HAR 逐组合对比。Accuracy 单位为百分比，数值越高越好。绿色向上箭头表示相对 X-Fi 提升，红色向下箭头表示退化。VK-RMD 结果列用浅灰色标注。

模态	X-Fi Acc.↑	VK-RMD Acc.↑	Δ Acc.
V	26.5	65.3	↑ 38.8
D	48.1	88.0	↑ 39.9
L	52.7	40.8	↓ 11.9
R	85.7	85.9	↑ 0.2
V+D	45.3	89.5	↑ 44.2
V+L	35.2	68.5	↑ 33.3
V+R	73.4	92.7	↑ 19.3
D+L	51.6	88.5	↑ 36.9
D+R	79.8	96.4	↑ 16.6
L+R	88.7	89.5	↑ 0.8
V+D+L	48.7	89.6	↑ 40.9
V+D+R	70.7	96.6	↑ 25.9
V+L+R	77.8	92.7	↑ 14.9
D+L+R	80.5	96.4	↑ 15.9
V+D+L+R	72.2	96.6	↑ 24.4

HAR 结果呈现出




图 3: 模态子集上的学习可靠性代理权重。该权重是任务级贡献指标，不是校准的传感器健康度量。

展示 FSG 学生在不同模态可用性条件下的退化曲线。HPE 中, Student-VK 从完整模态的 50.2/33.5 mm 逐步退化到缺失 4 个模态时的 124.8/68.0 mm; Student-NV 在 severe missing 下退化更明显。HAR 中, Student-VK 在缺失 1 个和 2 个模态时仍保持 93.8% 和 87.5% accuracy, 缺失 3 个模态时下降到 70.0%。这说明 FSG 的价值主要体现在多种可用子集均需支持的部署压力测试中。

Leave-on

表 4: Leave-one-out 关键模态分析。HPE 数值为移除该模态后的误差增加量; HAR 数值为移除该模态后的准确率/F1 下降量。

Removed	HPE ΔMPJPE	HPE ΔPA	HAR ΔAcc.	HAR ΔF1
V	1.6	1.1	0.1	0.1
D	14.1	5.3	3.8	3.7
L	0.2	0.1	0.0	0.0
R	0.9	0.7	6.9	7.1
W	0.1	-0.0	—	—

跨协议结果

5.2 FSG 的缺失模态核心结果

直接 X-Fi 风格比较回答“V 替代 RGB 后是否仍然有效”，而本节回答第二条主线：在真实部署中传感器缺失时，FSG 训练出的学生是否比简单完整模态模型或均匀融合更稳。因此，表 ?? 和表 ?? 不是附录或弱补充，而是本文证明 FSG 的正文核心结果。在 HPE 中，均匀融合为 82.77 mm，而 VK-RMD Student-VK 在 all-subset stress test 中为 75.18 mm，说明学习得到的子集加权优于等权重。在 HAR 中，Student-VK 为 85.15%，高于均匀融合的 67.46% 以及缺失模态测试下完整模态教师的 66.25%。这些结果显示 FSG 改善的是模态可用性空间，而不仅是完整模态端点。

表 ?? 按缺失数量汇总 all-subset stress test，直接

5.3 FSG 的融合机制分析

可靠性融表 ?? 给出核心消融。Uniform fusion 在 HPE 和 HAR 上均弱于 VK-RMD，说明当前可用子集下的学习融合是必要的。w/o distillation 在 HPE 上竞争力很强，因此本文不声称 FSG 中的 teacher 约束是唯一收益来源；在 HAR 上，w/o distillation 低于完整 VK-RMD，说明完整模态行为约束对动作识别仍有辅助收益。

表 6: 核心消融结果。HPE 数值为 MPJPE，HAR 数值为 Accuracy。

Task	Setting	Avg.	Full
HPE	VK-RMD	75.18 mm MPJPE	50.17 mm MPJPE
HPE	w/o distillation	72.68 mm MPJPE	48.83 mm MPJPE
HPE	uniform fusion	82.77 mm MPJPE	52.28 mm MPJPE
HAR	VK-RMD	85.15% accuracy	96.56% accuracy
HAR	w/o distillation	82.86% accuracy	95.99% accuracy
HAR	uniform fusion	67.46% accuracy	95.39% accuracy

本文还进行了轻量合成腐蚀诊断。图 ?? 表明，腐蚀模态会改变性能和学习权重。该结果应谨慎解释：部分被腐蚀模态权重下降，但 HPE 中 D 被腐蚀后权重上升，同时误差明显增大。这说明该代理捕捉的是模型目标下的学习贡献，而不是真实物理可靠性。该诊断属于机制边界分析，其价值在于防止过度声称，并明确可靠性模块代表什么、不代表什么。

5.4 低视觉暴露与身份泄露探针


下表定
结果显

表 3: FSG 缺失强度核心结果。HPE 为 MPJPE/PA-MPJPE, 越低越好; HAR 为 Acc./F1, 越高越好。

缺失数	HPE↓				HAR↑			
	VK MPJPE	VK PA	NV MPJPE	NV PA	VK Acc.	VK F1	NV Acc.	NV F1
0	50.2	33.5	51.0	35.7	96.6	96.5	96.1	96.1
1	53.5	34.9	61.3	40.5	93.8	93.8	90.1	90.0
2	60.8	38.1	79.4	50.7	87.5	87.6	66.0	65.7
3	78.1	46.8	124.3	71.2	70.0	69.9	—	—
4	124.8	68.0	—	—	—	—	—	—

表 5: 跨协议泛化核心结果。HPE 为平均/全模态 MPJPE, HAR 为平均/全模态 Accuracy。

Protocol	Model	HPE Avg.↓	HPE Full↓	HAR Avg.↑	HAR Full↑
random split	VK-RMD VK	75.18	50.17	85.15	96.56
random split	VK-RMD NV	84.68	51.03	80.62	96.12
cross-subject	VK-RMD VK	78.57	49.88	85.30	96.12
cross-subject	VK-RMD NV	90.74	52.45	81.26	95.70
cross-scene	VK-RMD VK	142.02	71.71	80.61	95.25
cross-scene	VK-RMD NV	153.89	78.96	76.70	95.41



Noise/random zeroing on 100 validation batches. Weight changes are learned contribution proxies, not calibrated physical sensor reliability.

图 4: 合成模态腐蚀下的可靠性代理。实验在 100 个验证 batch 上加入噪声和随机置零。该代理会响应模态扰动, 但不应被理解为校准的物理传感器可靠性。

表 7: 视觉暴露与残余隐私风险。

5.5 Body-Latent 诊断

本文进行了一个

6 讨论

6.1 两条主线如何贯通

本文的结果应

6.2 与 X-Fi/VK 的关系

X-Fi/VK

6.3 FSG 与传统蒸馏的边界


FSG 使用

6.4 跨场景边界

跨场景 HPE

表 8: Action-holdout 划分下的主体身份泄露探针。高于随机水平的准确率表示存在残余身份相关信息。

表示	主体识别准确率	随机倍数	相对 RGB 降低
脱敏 RGB	67.53%	27.01×	0.00%
V	15.43%	6.17×	77.15%
D	43.80%	17.52×	35.14%
L	36.57%	14.63×	45.84%
R	9.72%	3.89×	85.60%
W	8.65%	3.46×	87.19%



Diagnostic only: high accuracy indicates residual identity leakage; low accuracy does not prove anonymity.

图 5: 主体身份泄露诊断。VK 相比脱敏 RGB 显著降低身份可预测性, 但仍高于随机水平。因此, 本文只主张降低视觉暴露和下游 RGB-free 推理, 不主张匿名性或形式化隐私保护。

6.5 探索性 Super-Teacher 说明

本文还探索了

7 结论

本文提出 VK-RMD, 一个围绕 VK 替代 RGB 与 Full-to-Subset Guidance 构建的缺失模态多模态人体感知框架。第一, VK 将下游模型从原始 RGB 流中解耦, 显著降低身份外观暴露风险, 但不提供匿名性或形式化隐私保证。第二, FSG 让完整模态教师学习完整感知行为, 并约束随机缺失模态学生在任意可用子集下工作, 从而区别于传统模型压缩式蒸馏。HPE 和 HAR 实验证明, Student-VK 与 Student-NV 在 X-Fi 风格逐组合对比、all-subset stress test 和内部融合消融中具有稳定的缺失模态可用性。本文也报告了重要边界: VK 仍含