

VK-RCD: 面向隐私友好与任意模态缺失的人体感知蒸馏框架

基于官方 X-Fi 结果的系统对比版

作者姓名¹ 作者姓名¹ 作者姓名¹

¹ 单位名称

email@example.com

摘要

多模态人体感知通过融合 RGB、Depth、LiDAR、mmWave 和 WiFi-CSI 等传感器完成三维人体姿态估计 (HPE) 与人体动作识别 (HAR)。官方 X-Fi 工作证明了单一模型处理任意模态组合的可行性,但其视觉分支仍依赖原始 RGB 图像,且在真实部署中仍需要面对隐私保护、模态缺失、传感器退化和跨任务迁移等问题。本文提出 VK-RCD,一种以视觉关键点 (Visual Keypoints, VK) 替代原始 RGB 的隐私友好缺失模态蒸馏框架。我们首先构建全模态 Teacher 吸收 VK、Depth、LiDAR、mmWave 和 WiFi-CSI 中的互补结构信息;随后训练 Student 在随机缺失 1 到多种模态的条件下对齐 Teacher 输出和中间表征,并通过可靠性感知融合为不同模态组合分配动态决策权。与官方 X-Fi 的公开结果相比,在 MM-Fi 随机划分协议下,本文 Student-VK 在 HPE 全模态组合中将 MPJPE 从 83.7 mm 降至 50.2 mm (+40.1%), PA-MPJPE 从 47.6 mm 降至 33.5 mm (+29.7%);在 HAR 全模态组合中,准确率由官方 X-Fi 的 72.2% 提升至 96.6% (+33.7%)。更重要的是,本文系统报告了 31 种 HPE 组合和 15 种 HAR 组合的逐组合对比,并给出 VK 缺失、非视觉 Student、蒸馏消融和跨场景实验的当前结果,为后续冲刺 CCF-A/B 级投稿提供可复现实验基线。

1 引言

人体感知是智能家居、康复评估、人机交互、公共安全和机器人协作中的关键基础能力。以 RGB 为核心的视觉方法能够提供丰富的纹理和空间信息,但也不可避免地记录面部、服饰、身份、背景和生活环境等隐私敏感信息。在真实家庭和医疗场景中,用户往往愿意接受姿态骨架、深度、毫米波或无线信号,却不愿意长期暴露原始图像。因此,人体感知系统的下一步发展不应只追求更高精度,还应同时满足隐私友好、可部署、可缺失和跨任务复用。

官方 X-Fi 框架为多模态人体感知提供了重要起点:它通过模态特定编码器、统一投影空间和 X-Fusion 结构,使一个模型能够在多种模态组合下运行。本文并不简单重复 X-Fi 的任意模态输入,而是围绕真实部署重新定义问题:第一,视觉输入从原始 RGB 改为 VK,使模型利用人体结构而不是身份外观;第二,训练阶段引入 Teacher-Student 蒸馏,使全模态知识服务于缺失模态 Student;第三,测试阶段不只被动接受模态组合,而是根据当前组合的可靠性动态调整融合权重;第四,同一思想同时应用于 HPE 回归和 HAR 分类两类任务。

本文的贡献如下。

- **隐私友好视觉替换。**将官方 X-Fi 中的 RGB 分支替换为轻量级 VK 分支,保留人体结构和动作信息,弱化纹理、身份和背景信息。

- **缺失模态蒸馏。**构建全模态 Teacher 和随机缺失 Student，使 Student 在训练阶段主动经历不同缺失模式，而不是只在测试阶段被动退化。
- **可靠性感知决策。**在 uncertainty、attention 和 uniform 三类策略中，以不确定性或模态可靠性动态调节不同模态的决策权。
- **官方 X-Fi 逐组合对比。**在 HPE 的 31 种模态组合和 HAR 的 15 种模态组合上，与官方 X-Fi 数值逐项对齐，报告绝对差值和相对变化幅度。
- **跨任务统一验证。**同一框架覆盖 HPE 和 HAR，并给出非视觉 Student、无蒸馏消融、跨场景实验和待补充实验矩阵。

2 相关工作

2.1 多模态人体感知

多模态人体感知利用多个传感器从不同物理视角观察人体。RGB 提供纹理和二维外观，Depth 提供距离和轮廓，LiDAR 提供稀疏三维几何，mmWave 提供弱光鲁棒和一定穿透能力，WiFi-CSI 提供低成本、非接触、隐私友好的无线信道变化。单一模态往往存在明显短板：RGB 依赖光照且隐私风险高，Depth 受距离和遮挡影响，LiDAR 成本较高，mmWave 点云稀疏，WiFi-CSI 空间分辨率较低。多模态融合的核心价值正是让不同模态在人体结构、运动趋势和环境鲁棒性上互补。

2.2 任意模态组合与缺失模态学习

真实部署中的传感器集合经常变化：某些传感器可能因故障、遮挡、权限限制、采样异常或能耗控制而缺失。传统固定融合方法需要为每个模态组合训练单独模型，组合数随模态数指数增长。官方 X-Fi 通过模态不变训练和跨模态融合缓解了这一问题。本文进一步强调训练时随机缺失，使 Student 在训练分布中主动看到缺失模式，并借助全模态 Teacher 传递缺失时难以直接学习的结构知识。

2.3 知识蒸馏与隐私保护

知识蒸馏通常利用强 Teacher 指导轻量 Student，使 Student 获得更稳定的输出分布或中间表示。在本文中，Teacher 不是最终部署模型，而是训练阶段的特权知识源：它使用全模态输入学习完整人体结构，再把知识传递给可缺失 Student。与直接使用 RGB 不同，本文 VK 分支只编码人体关键点坐标，从输入层降低隐私暴露风险。需要说明的是，VK 本身仍可能来自上游视觉估计或数据集提供，因此本文的隐私主张是“部署输入不使用原始 RGB 图像”，并不等价于完全不可逆匿名化。

3 方法

3.1 问题定义

给定模态集合 $\mathcal{M} = \{VK, D, L, R, W\}$ ，其中 D, L, R, W 分别代表 Depth、LiDAR、mmWave 和 WiFi-CSI。对于任意可用子集 $\mathcal{S} \subseteq \mathcal{M}$ ，模型需要输出 HPE 任务中的三维人体关节 $\hat{\mathbf{Y}} \in \mathbb{R}^{17 \times 3}$ ，或 HAR 任务中的动作类别分布 $\hat{\mathbf{p}} \in \mathbb{R}^C$ 。官方 X-Fi 中的 I 表示 RGB 图像；本文在对比表中写作 I/VK ，表示官方列使用 RGB，而本文对应位置使用 VK 关键点。

3.2 VK 轻量级编码器

本文废弃原始 RGB ResNet-18 分支，将每帧 17 个人体关键点作为输入。对第 j 个关节坐标 $\mathbf{u}_j \in \mathbb{R}^2$ ，首先使用共享线性层映射到高维关节表征：

$$\mathbf{h}_j = \phi(\mathbf{W}_v \mathbf{u}_j + \mathbf{b}_v), \quad j = 1, \dots, 17. \quad (1)$$

随后将 17 个关节 token 沿关节维度交互，通过线性投影获得结构级 VK token。与展平所有像素或使用大规模 CNN 相比，该设计参数更少、输入更干净，并且直接围绕人体结构建模。

3.3 全模态 Teacher 与随机缺失 Student

Teacher 使用训练阶段可获得的全模态输入，学习强跨模态表征。Student 使用相同任务头，但在训练时随机采样可用模态子集：

$$\mathcal{S} \sim q(\mathcal{S}), \quad 1 \leq |\mathcal{S}| \leq |\mathcal{M}|. \quad (2)$$

对 HPE 任务，Student 优化监督回归损失、Teacher 输出蒸馏损失和特征对齐损失：

$$\mathcal{L}_{HPE} = \|\hat{\mathbf{Y}}_s - \mathbf{Y}\|_2^2 + \lambda_o \|\hat{\mathbf{Y}}_s - \hat{\mathbf{Y}}_t\|_2^2 + \lambda_f \|\mathbf{z}_s - \mathbf{z}_t\|_2^2. \quad (3)$$

对 HAR 任务，Student 优化交叉熵、KL 蒸馏和特征对齐：

$$\mathcal{L}_{HAR} = \text{CE}(\hat{\mathbf{p}}_s, y) + \lambda_k T^2 \text{KL}(\sigma(\mathbf{l}_t/T) \parallel \sigma(\mathbf{l}_s/T)) + \lambda_f \|\mathbf{z}_s - \mathbf{z}_t\|_2^2. \quad (4)$$

3.4 可靠性感知融合

本文比较三类决策策略。**Uniform** 为所有可用模态分配相同权重，是最朴素的平均融合基线。**Attention** 从融合 token 中学习模态权重，依赖数据驱动的相关性建模。**Uncertainty** 根据模态输出的不确定性分配权重，直觉上更可靠的模态获得更高决策权：

$$\alpha_m = \frac{\exp(-u_m/\tau)}{\sum_{k \in \mathcal{S}} \exp(-u_k/\tau)}, \quad \hat{\mathbf{y}} = \sum_{m \in \mathcal{S}} \alpha_m \hat{\mathbf{y}}_m. \quad (5)$$

其中 u_m 表示第 m 个模态的不确定性估计， τ 为温度系数。本文当前已完成的结果主要对应 uncertainty 策略；attention 和 uniform 完整三协议结果仍需继续补齐。

4 实验设置

4.1 数据集与任务

本文使用 MM-Fi 数据集。HPE 任务使用 VK、Depth、LiDAR、mmWave 和 WiFi-CSI 五类输入，输出 17 个三维人体关节。HAR 任务使用 VK、Depth、LiDAR 和 mmWave 四类输入，输出 27 类动作标签；按照官方设置，HAR 不使用 WiFi-CSI，因为单帧 WiFi 样本时间窗口较短，难以稳定覆盖动作序列模式。

4.2 评价指标

HPE 使用 MPJPE 和 PA-MPJPE，单位为毫米，数值越低越好。HAR 使用 Accuracy 和 Macro-F1，数值越高越好。本文所有与官方 X-Fi 的对比均遵循如下颜色规则：HPE 中 $\Delta = \text{X-Fi} - \text{Ours}$ ，HAR 中 $\Delta = \text{Ours} - \text{X-Fi}$ ；**蓝色**表示本文结果更优，**红色**表示本文结果更差。

4.3 实验协议

当前本地已同步的实验主要包括 random split 下的 HPE/HAR、HAR cross-scene、HPE 非视觉 Student、HAR 非视觉 Student 和 HAR 无蒸馏消融。完整论文版本仍需补齐 cross-subject/action、HPE cross-scene 以及三种融合策略的全矩阵。表1列出当前状态。

表 1: 当前实验矩阵与完成状态

任务	Random split	Cross-subject/action	Cross-scene	融合策略
HPE Teacher	已完成全模态与 31 组合评估	[待补充: 待跑]	[待补充: 待跑]	当前 uncertainty 为主
HPE Student-VK	已完成 31 组合与缺失统计	[待补充: 待跑]	[待补充: 待跑]	uncertainty 完成, attention/uniform 待补
HPE Student-NV	已完成 15 个非视觉组合	[待补充: 待跑]	[待补充: 待跑]	uncertainty 完成
HAR Teacher	已完成 15 组合评估	[待补充: 待跑]	已完成全模态	uncertainty 为主
HAR Student-VK	已完成 15 组合评估	[待补充: 待跑]	已完成全模态	uncertainty 完成, attention/uniform 待补
HAR Student-NV	已完成 7 个非视觉组合	[待补充: 待跑]	[待补充: 待跑]	uncertainty 完成

5 与官方 X-Fi 的主要结果对比

5.1 HPE: 按可用模态数量统计

表2首先按可用模态数量汇总官方 X-Fi 与本文 Student-VK。可以看到, 本文在单模态、双模态、三模态、四模态和全模态设置下均显著降低平均 MPJPE 与 PA-MPJPE。尤其在全模态设置下, MPJPE 从 83.7 mm 降至 50.2 mm; 在全部 31 个组合的平均值上, MPJPE 由 103.7 mm 降至 75.2 mm。

表 2: HPE 按可用模态数量的官方 X-Fi 与本文 Student-VK 平均对比。HPE 越低越好, 蓝色表示本文误差更低。

可用模态数	组合数	X-Fi MPJPE	Ours MPJPE	Imp↑	X-Fi PA	Ours PA	Imp↑
1	5	143.2	124.7	+12.9%	77.4	68.0	+12.2%
2	10	105.0	78.1	+25.6%	59.7	46.9	+21.6%
3	10	92.6	60.8	+34.4%	52.3	38.1	+27.2%
4	5	87.9	53.5	+39.1%	49.6	34.9	+29.6%
5	1	83.7	50.2	+40.1%	47.6	33.5	+29.7%
平均	31	103.7	75.2	+27.5%	58.2	45.1	+22.5%

5.2 HAR: 按可用模态数量统计

表3给出 HAR 随机划分下的官方 X-Fi 与 Student-VK 对比。官方 X-Fi 在 HAR 单模态时部分模态较弱, 本文 Student-VK 经过缺失模态训练后, 在单模态和多模态条件下均保持较高分类性能。全模态准确率由 72.2% 提升到 96.6%。

表 3: HAR 按可用模态数量的官方 X-Fi 与本文 Student-VK 平均对比。HAR 越高越好, 蓝色表示本文准确率更高。

可用模态数	组合数	X-Fi Acc	Ours Acc	Δ	Rel.Imp $\uparrow$
1	4	53.2	70.0	+16.8	+31.5%
2	6	62.3	87.5	+25.2	+40.4%
3	4	69.4	93.8	+24.4	+35.2%
4	1	72.2	96.6	+24.4	+33.7%
平均	15	62.5	85.1	+22.7	+36.3%

6 缺失模态鲁棒性分析

6.1 HPE 随机缺失统计

表4显示 Student-VK 在不同缺失数量下的平均性能。随着可用模态减少, MPJPE 逐步上升, 这是符合预期的; 但即使只剩单模态, 模型仍保持可用输出, 而不是因结构固定而无法运行。该结果支撑本文“任意模态组合可部署”的核心主张。

表 4: HPE Student-VK 在不同缺失模态数量下的平均性能。

可用模态数	缺失模态数	组合数	MPJPE(mm)	PA-MPJPE(mm)
5	0	1	50.2	33.5
4	1	5	53.5	34.9
3	2	10	60.8	38.1
2	3	10	78.1	46.8
1	4	5	124.7	68.0

6.2 非视觉 Student

实际部署中, VK 本身也可能不可用。因此本文训练 Student-NV, 仅使用 Depth、LiDAR、mmWave 和 WiFi-CSI (HPE) 或 Depth、LiDAR 和 mmWave (HAR)。表9和表5显示, 在不使用任何视觉输入时, 部分非视觉组合仍能接近或超过官方 X-Fi 的对应组合, 说明本文的蒸馏与缺失训练并不完全依赖 VK。

表 5: HAR 非视觉 Student-NV 与官方 X-FI 对应非视觉组合对比。

组合	X-FI Acc	Ours Acc	Δ	Rel.Imp $\uparrow$	Ours F1
D	48.1	88.6	+40.5	+84.1%	88.5
L	52.7	26.1	-26.6	-50.4%	25.0
R	85.7	83.4	-2.3	-2.7%	83.6
D+L	51.6	88.7	+37.1	+71.9%	88.6
D+R	79.8	96.2	+16.4	+20.5%	96.2
L+R	88.7	85.3	-3.4	-3.8%	85.4
D+L+R	80.5	96.1	+15.6	+19.4%	96.1

7 消融实验

7.1 蒸馏作用

蒸馏的价值不只体现在全模态精度，还体现在缺失组合下的稳定性。表6比较 HAR Student-VK 与无蒸馏训练版本。整体上，蒸馏模型在大部分组合上取得更高准确率或更稳定 Macro-F1，说明 Teacher 提供的软标签和中间表征能缓解缺失模态训练中的组合稀疏问题。

表 6: HAR 消融：无蒸馏训练与 Student-VK 蒸馏训练对比。

组合	NoKD Acc	KD Acc	Δ	Rel.Imp $\uparrow$	KD F1
I/VK	60.9	65.3	+4.4	+7.2%	65.7
D	86.8	88.0	+1.2	+1.4%	87.9
L	33.1	40.8	+7.7	+23.1%	40.1
R	83.1	85.9	+2.7	+3.3%	86.1
I/VK+D	88.1	89.5	+1.4	+1.6%	89.4
I/VK+L	63.6	68.5	+4.9	+7.7%	69.1
I/VK+R	91.1	92.7	+1.7	+1.9%	92.8
D+L	87.2	88.5	+1.3	+1.5%	88.4
D+R	95.6	96.4	+0.9	+0.9%	96.4
L+R	85.9	89.5	+3.6	+4.2%	89.6
I/VK+D+L	88.6	89.6	+1.0	+1.1%	89.5
I/VK+D+R	96.0	96.6	+0.6	+0.6%	96.5
I/VK+L+R	91.2	92.7	+1.5	+1.6%	92.8
D+L+R	95.5	96.4	+0.9	+1.0%	96.4
I/VK+D+L+R	96.0	96.6	+0.6	+0.6%	96.5

7.2 跨场景初步结果

当前已同步 HAR cross-scene 全模态结果：Teacher 在跨场景设置下达到 94.80% Accuracy 与 94.83% Macro-F1；Student-VK 达到 95.25% Accuracy 与 95.25% Macro-F1。该结果说明缺失模态 Student 并不必然牺牲跨环境泛化，但完整结论仍需补齐 cross-subject/action 与不同融合策略。

8 讨论

8.1 为什么 VK 替代 RGB 仍可能提升性能

本文并不是把 RGB 简单替换为一个更小的 MLP，而是改变了视觉信息的语义粒度。RGB 包含大量任务无关因素，如纹理、光照、背景和身份信息；VK 则直接保留人体结构。对于 HPE 和 HAR 这类以关节几何和动作趋势为核心的任务，VK 降低了学习难度，也减少了模型从背景捷径中学习的风险。因此，VK 在隐私友好之外，还可能带来优化和泛化优势。

8.2 为什么 Teacher 不是最终创新本身

Teacher 本身更多是训练工具，不是最终贡献。真正的创新在于：利用全模态 Teacher 作为特权知识源，把完整模态下的结构知识蒸馏给能够任意缺失的 Student；最终部署的是 Student-VK 或 Student-NV。换言之，Teacher 提供上限和知识来源，Student 提供部署形态，随机缺失训练和可靠性感知融合提供鲁棒性。

8.3 当前结果的边界

本文当前版本仍有三个边界需要在投稿前处理。第一，官方 X-FI 的 RGB 与本文 VK 不是完全相同输入，表格中的 I/VK 对比应解释为“视觉位置的替代方案对比”，而不是同一原始输入的严格同构比较。第二，cross-subject/action 与 HPE cross-scene 结果尚未完全补齐。第三，uncertainty、attention、uniform 三种融合策略需要在三类协议下形成完整矩阵，才能将“动态决策策略”的贡献从工程现象提升为论文主结论。

9 结论

本文提出 VK-RCD，在官方 X-FI 任意模态人体感知框架基础上，引入 VK 隐私友好视觉替代、全模态 Teacher 蒸馏、随机缺失 Student 训练和可靠性感知融合。与官方 X-FI 相比，当前 random split 结果在 HPE 和 HAR 上均显示出明显优势，尤其是逐组合对比证明 Student-VK 能够在大多数甚至全部已评估组合下稳定工作。后续若补齐跨人/动作、跨场景和三种融合策略的完整消融，并进一步解释 VK 来源与隐私边界，本文具备冲击 CCF-B 并争取 CCF-A 相关方向会议的实验基础。

A HPE 逐组合官方对比

表7给出 HPE 31 种组合的逐项对比。注意：官方 I 为 RGB，本文对应 I/VK 为关键点 VK。

表 7: HPE 31 组合：官方 X-FI 与本文 Student-VK 逐组合对比。MPJPE/PA-MPJPE 单位为 mm。

组合	X-FI MPJPE	Ours MPJPE	Δ	Imp $\uparrow$	X-FI PA	Ours PA	Imp $\uparrow$
I/VK	93.9	92.7	+1.2	+1.3%	60.3	42.6	+29.3%
D	101.8	53.9	+47.9	+47.1%	48.4	35.6	+26.4%
L	167.1	139.9	+27.2	+16.3%	103.2	93.4	+9.5%
R	127.4	115.0	+12.4	+9.8%	69.8	58.1	+16.7%
W	225.6	222.1	+3.5	+1.5%	105.3	110.2	-4.6%
I/VK+D	86.1	51.7	+34.4	+40.0%	48.1	34.3	+28.7%
I/VK+L	93.0	73.2	+19.8	+21.3%	59.7	41.9	+29.8%

组合	X-F1 MPJPE	Ours MPJPE	Δ	Imp $\uparrow$	X-F1 PA	Ours PA	Imp $\uparrow$
I/VK+R	88.8	68.9	+19.9	+22.4%	57.3	38.9	+32.1%
I/VK+W	93.0	88.1	+4.9	+5.3%	59.5	42.3	+28.9%
D+L	102.5	53.0	+49.5	+48.3%	48.4	35.3	+27.0%
D+R	98.0	52.3	+45.7	+46.6%	47.3	34.6	+26.8%
D+W	101.8	53.5	+48.3	+47.4%	48.1	35.5	+26.2%
L+R	109.8	97.5	+12.3	+11.2%	63.4	55.1	+13.1%
L+W	159.5	134.1	+25.4	+15.9%	102.7	93.2	+9.2%
R+W	117.2	108.5	+8.7	+7.4%	62.7	57.3	+8.7%
I/VK+D+L	84.8	51.1	+33.7	+39.7%	48.2	34.2	+29.1%
I/VK+D+R	83.4	50.5	+32.9	+39.5%	47.3	33.5	+29.1%
I/VK+D+W	85.3	51.6	+33.7	+39.5%	48.1	34.3	+28.7%
I/VK+L+R	88.4	66.1	+22.3	+25.2%	57.2	38.8	+32.2%
I/VK+L+W	93.0	70.7	+22.3	+24.0%	59.7	41.8	+30.1%
I/VK+R+W	88.5	66.7	+21.8	+24.6%	57.1	38.8	+32.1%
D+L+R	96.0	51.9	+44.1	+45.9%	47.3	34.5	+27.1%
D+L+W	102.0	52.9	+49.1	+48.2%	48.1	35.4	+26.4%
D+R+W	97.0	52.1	+44.9	+46.3%	47.1	34.6	+26.5%
L+R+W	107.4	94.2	+13.2	+12.3%	63.1	55.1	+12.7%
I/VK+D+L+R	83.5	50.3	+33.2	+39.8%	47.6	33.4	+29.7%
I/VK+D+L+W	86.0	51.0	+35.0	+40.6%	48.2	34.2	+29.1%
I/VK+D+R+W	84.0	50.4	+33.6	+40.0%	47.6	33.5	+29.5%
I/VK+L+R+W	88.6	64.2	+24.4	+27.5%	57.1	38.8	+32.1%
D+L+R+W	97.6	51.8	+45.8	+46.9%	47.4	34.5	+27.1%
I/VK+D+L+R+W	83.7	50.2	+33.5	+40.1%	47.6	33.5	+29.7%

B HAR 逐组合官方对比

表 8: HAR 15 组合: 官方 X-F1 与本文 Student-VK 逐组合对比。Accuracy/Macro-F1 单位为%。

组合	X-F1 Acc	Ours Acc	Δ	Rel.Imp $\uparrow$	Ours F1
I/VK	26.5	65.3	+38.8	+146.5%	65.7
D	48.1	88.0	+39.9	+83.0%	87.9
L	52.7	40.8	-11.9	-22.6%	40.1
R	85.7	85.9	+0.2	+0.2%	86.1
I/VK+D	45.3	89.5	+44.2	+97.6%	89.4
I/VK+L	35.2	68.5	+33.3	+94.7%	69.1
I/VK+R	73.4	92.7	+19.3	+26.4%	92.8
D+L	51.6	88.5	+36.9	+71.5%	88.4
D+R	79.8	96.4	+16.6	+20.9%	96.4
L+R	88.7	89.5	+0.8	+0.9%	89.6
I/VK+D+L	48.7	89.6	+40.9	+84.0%	89.5
I/VK+D+R	70.7	96.6	+25.9	+36.6%	96.5
I/VK+L+R	77.8	92.7	+14.9	+19.2%	92.8
D+L+R	80.5	96.4	+15.9	+19.8%	96.4
I/VK+D+L+R	72.2	96.6	+24.4	+33.7%	96.5

C HPE 非视觉 Student-NV 逐组合结果

表 9: HPE 非视觉 Student-NV 与官方 X-Fi 对应非视觉组合对比。

组合	X-Fi MPJPE	Ours MPJPE	Imp↑	X-Fi PA	Ours PA	Imp↑
D	101.8	52.3	+48.6%	48.4	36.4	+24.7%
L	167.1	123.1	+26.3%	103.2	84.2	+18.4%
R	127.4	109.4	+14.1%	69.8	57.5	+17.6%
W	225.6	212.4	+5.9%	105.3	106.9	-1.5%
D+L	102.5	52.0	+49.2%	48.4	36.4	+24.8%
D+R	98.0	51.2	+47.7%	47.3	35.9	+24.2%
D+W	101.8	52.5	+48.5%	48.1	36.4	+24.4%
L+R	109.8	91.2	+17.0%	63.4	54.1	+14.7%
L+W	159.5	123.6	+22.5%	102.7	84.0	+18.2%
R+W	117.2	106.1	+9.5%	62.7	57.4	+8.4%
D+L+R	96.0	51.1	+46.8%	47.3	35.7	+24.4%
D+L+W	102.0	52.0	+49.0%	48.1	36.4	+24.4%
D+R+W	97.0	51.2	+47.2%	47.1	35.8	+24.1%
L+R+W	107.4	91.1	+15.2%	63.1	54.2	+14.1%
D+L+R+W	97.6	51.0	+47.7%	47.4	35.7	+24.7%

D 待补充实验表

表 10: 投稿前需要补齐的关键实验。

实验块	需要补齐的内容	目的	当前处理
Cross-subject/action	HPE/HAR Teacher、Student-VK、Student-NV	验证跨人群和跨动作泛化	留白，云端继续跑
Cross-scene HPE	E01–E03 训练, E04 测试等	验证跨环境泛化	留白
融合策略矩阵	uncertainty、attention、uniform 三策略	证明动态决策贡献	当前以 uncertainty 为主
Teacher 缺失训练对比	全模态 Teacher vs 缺失训练 Teacher	回答为何采用 Student 而非直接缺失训练	Teacher–Teacher 建议补跑
VK 来源鲁棒性	GT-VK/检测器 VK/噪声 VK	支撑隐私友好部署可信度	已有噪声脚本，需整理进表

参考文献

- [1] Anonymous authors. X-Fi: A Modality-Invariant Foundation Model for Human Sensing. ICLR 2025 conference paper, arXiv:2410.10167v3, 2025.
- [2] Jianfei Yang et al. MM-Fi: Multi-Modal Non-Intrusive 4D Human Dataset for Versatile Wireless and Vision Sensing. 2024.
- [3] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the Knowledge in a Neural Network. NeurIPS Deep Learning Workshop, 2015.

- [4] Charles R. Qi et al. PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation. CVPR, 2017.
- [5] Hengshuang Zhao et al. Point Transformer. ICCV, 2021.
- [6] Yunjiao Zhou et al. MetaFi++: WiFi-enabled Transformer-based Human Pose Estimation for Metaverse Avatar Simulation. IEEE Internet of Things Journal, 2023.
- [7] Mengmeng Ma et al. Are Multimodal Transformers Robust to Missing Modality? CVPR, 2022.
- [8] Qi Wang et al. Multimodal Learning with Incomplete Modalities by Knowledge Distillation. KDD, 2020.
- [9] Zihui Xue and Radu Marculescu. Dynamic Multimodal Fusion. CVPR, 2023.