

VK-RMD: 面向低视觉暴露与缺失模态鲁棒的多模态人体感知

Eagle

Abstract—人体感知是智能空间、人机交互、健康监测和具身智能中的基础感知能力。现有多模态人体感知方法通常依赖稳定传感器组合和较固定的部署场景；然而，在线 RGB 输入会带来面部、衣着、背景和身份外观暴露风险，IoT 传感器又可能因遮挡、设备故障或通信中断而随机不可用。为此，本文提出 **VK-RMD**，一种面向低视觉暴露和随机传感器失效的多模态人体感知框架。本文使用 **Visual Keypoints (VK)** 作为在线结构输入，而不是将原始 RGB 输入部署模型；VK 可以由前端脱敏姿态估计模块或其他能够输出人体骨架关键点的感知设备提供。身份泄露探针显示，在相同主体识别设置下，VK 的主体识别准确率为 **15.43%**，低于脱敏 RGB 的 **67.53%**，说明 VK 能显著降低下游模型中的身份外观可预测性，但本文不声称形式化安全承诺。进一步地，本文将完整模态教师到随机缺失模态学生的监督机制具体化为 **Full-to-Subset Guidance (FSG)**：教师模型学习完整传感器可用时的感知行为，学生模型在随机模态子集下学习逼近教师的输出、结构 token 和融合行为。本文在 **MMFi** 数据集的人体姿态估计 (HPE) 和人体活动识别 (HAR) 任务上进行系统评估，覆盖 HPE 的 31 种模态组合和 HAR 的 15 种模态组合，并报告 **random split**、**cross-subject** 和 **cross-scene** 协议下的结果。与 **X-Fi** 原文表项对齐比较，VK-RMD 在完整模态设置下将 HPE 的 **MPJPE** 从 **83.7 mm** 降至 **50.2 mm**，将 HAR 准确率从 **72.2%** 提升至 **96.6%**。同时，本文通过缺失强度、**leave-one-out**、消融、可靠性权重、身份泄露探针和部署效率分析展示了该框架在低视觉暴露和动态传感器可用性条件下的适用边界。

Index Terms—多模态人体感知，**Visual Keypoints**，缺失模态学习，人体姿态估计，人体活动识别，**IoT** 感知。

I. 引言

人体感知旨在从环境传感器中恢复人体姿态、动作和行为状态，是智能空间、人机交互、健康监测、辅助生活和具身智能中的基础能力。随着 RGB 相机、Depth、LiDAR、毫米波雷达和 WiFi-CSI 等传感器的发展，多模态人体感知已经能够在人体姿态估计 (Human Pose Estimation, HPE) 和人体活动识别 (Human Activity Recognition, HAR) 中获得较高性能。然而，当系统从实验室条件走向开放 IoT 部署时，核心挑战不再只是如何融合更多模态，而是如何在低视觉暴露、随机传感器缺失和场景变化同时存在时保持稳定感知。

首先，RGB 视觉信号在人体感知中具有强语义信息，但也携带面部、衣着、背景和身份外观等敏感信息。直接将 RGB 输入在线部署模型会扩大视觉暴露范围，尤其在家庭、康复、办公和公共空间等隐私敏感场景中更难被接受。与原始图像不同，**Visual Keypoints (VK)** 保留人体关节位置和骨架结构，削弱纹理、背景和面部外观信息。因此，VK 可以作为一种低外观结构输入用于下游感知。但 VK 并不等价于严格匿名：身高、体态、步态和动作习惯仍可能包含身份线索。本文将该方向界定为降低视觉暴露，而不是形式化隐私保护。

其次，真实 IoT 传感器并不总是稳定可用。Depth 可能受到遮挡影响，LiDAR 点云可能稀疏，毫米波雷达和 WiFi-CSI 对布设位置和环境变化敏感，某些设备也可能因故障、成本或权限限制而缺失。因此，一个只在固定模态组合上训练的模型，即使在完整输入下表现良好，也可能在随机缺失条件下快速退化。更进一步，跨主体和跨场景泛化仍然是人体感知中的长期难题：缺失模态鲁棒性并不自动意味着场景迁移鲁棒性。

为解决上述问题，本文提出 VK-RMD。其核心思想是将在线原始 RGB 替换为 VK 结构输入，并在缺失模态训练中使用完整模态教师约束随机子集学生。具体而言，模型首先通过模态专属编码器提取 VK、Depth、LiDAR、mmWave 和 WiFi-CSI 的特征，并投影到统一 body-token 空间；随后，跨模态 Transformer 建模当前可用模态子集中的交互关系；最后，模型通过 chunk 级专家分支和融合残差分支同时保留模态专属判断与跨模态互补信息。为增强随机缺失条件下的稳定性，本文引入 **Full-to-Subset Guidance (FSG)**，由完整模态教师向随机缺失模态学生提供输出、token、结构和融合层面的约束。

本文贡献总结如下。第一，本文提出一种低视觉暴露多模态人体感知框架，使用 **Visual Keypoints** 替代在线原始 RGB，在降低身份外观暴露的同时保留人体结构信息。第二，本文将完整模态到缺失模态的监督机制具体化为 FSG，通过完整模态教师约束随机缺失模态学生，使模型适应动态传感器可用性。第三，本文设计 chunk 级专家分支和融合残差分支相结合的多模态融合机制，并在 HPE 的 31 种模态组合、HAR 的 15 种模态组合以及 random split、cross-subject 和 cross-scene 协议下系统验证了 VK-RMD 的性能、边界和部署成本。

II. 相关工作

A. 人体感知

人体感知方法大体可分为视觉方法、非视觉传感器方法和多模态融合方法。视觉方法利用 RGB 图像或视频中的外观、纹理和空间上下文进行姿态估计和动作识别，并通过卷积网络、图模型和 Transformer 等结构取得较高性能 [3], [4], [7], [8]。这类方法的优势是语义清晰、标注体系成熟，但其输入也包含面部、衣着和背景等身份相关信息，在隐私敏感场景中存在视觉暴露风险。

非视觉传感器方法尝试利用 Depth、LiDAR、毫米波雷达和 WiFi-CSI 等信号捕获人体状态 [9]–[13], [15]。Depth 能提供较稳定的空间几何，LiDAR 能描述稀疏点云结构，毫米波雷达具有非接触和一定穿透能力，WiFi-CSI 可以利用无线信道扰动进行人体感知。然而，这些模态也受到噪声、遮挡、稀疏采样、环境布局和传感器安装位置影响。多模态融合方法通过特征级融合或决策级融合综合不同传感器的互补信息 [1], [2], [17]。固定特征融合在完整模态输

入下表现较好,但缺少动态模态适应能力;决策级融合更灵活,却容易受到弱模态或噪声模态影响。

B. 动态模态与缺失模态学习

缺失模态学习研究如何在部分输入不可用时维持模型性能。常见方法包括模态 dropout、模态补全、跨模态蒸馏、共享嵌入空间学习和门控融合 [22]–[29]。在人体感知中, X-Fi 提出模态不变人体感知框架,通过可变模态输入和融合模块支持多种传感器组合 [1]。这些工作为动态模态感知提供了重要基础,但仍存在两个问题:一是多数方法主要关注任意组合融合,而较少把低视觉暴露作为在线部署约束;二是缺失模态训练往往被视作正则化,而不是显式地把“完整传感器行为”迁移到“缺失传感器学生”。

本文与上述工作不同,并不把 VK 视为普通第五模态或 RGB 的简单压缩版本,而是将其作为在线下游模型中的结构输入;同时,本文将完整模态教师和随机子集学生之间的监督关系明确为 full-to-subset 的训练约束。该设计与传统模型压缩式知识蒸馏不同:教师和学生不一定存在模型大小差异,关键差异在于输入条件不同,即教师看到完整模态集合,而学生面对随机可用模态子集。

C. 低视觉暴露与结构化人体表示

隐私相关人体感知研究通常从降低图像分辨率、学习隐私保护光学前端、使用深度图或使用骨架表示等方向减少敏感外观信息 [30]–[32]。骨架关键点在动作识别和姿态分析中广泛使用 [3]–[6],其优势是保留人体关节结构而削弱纹理和背景信息。需要强调的是,骨架并非严格匿名表示,仍可能泄露体态、步态和动作习惯。因此,本文只声称 VK 降低在线 RGB 视觉暴露和主体识别可预测性,不声称差分隐私、密码学安全或身份不可恢复。

III. VK-RMD 框架

A. 问题定义

给定一个多模态样本 $\{x_m\}_{m \in \mathcal{M}}$ 及其标签 y , HPE 中的模态集合为 $\mathcal{M}_{hpe} = \{V, D, L, R, W\}$, HAR 中的模态集合为 $\mathcal{M}_{har} = \{V, D, L, R\}$ 。其中 V 表示 Visual Keypoints, D 表示 Depth, L 表示 LiDAR, R 表示 mmWave, W 表示 WiFi-CSI。训练学生模型时,模型从完整模态集合中随机采样一个非空可用子集:

$$S \sim q(S), \quad S \subseteq \mathcal{M}, \quad S \neq \emptyset. \quad (1)$$

目标是在任意可用子集 S 下预测 HPE 姿态或 HAR 动作类别,同时避免在线使用原始 RGB。

B. VK 结构输入与 body-token 编码

VK 输入不是图像,而是人体关键点坐标及其关节语义。对每个模态 m ,本文使用模态专属编码器 E_m 提取特征,并通过投影层 P_m 映射到统一 body-token 维度:

$$Z_m = P_m(E_m(x_m)) + e_m, \quad m \in S, \quad (2)$$

其中 e_m 是模态嵌入,用于保留 token 的模态来源。VK 分支采用关节级结构编码而非图像 backbone; Depth、LiDAR、mmWave 和 WiFi-CSI 分支则根据数据形态使用对应的视觉、点云或时序信号编码器。本文的对齐并不发生在原始空间:WiFi-CSI、LiDAR 点云、Depth 图和 VK 坐标不需要被强行映射成同一种原始数据,而是在任务监督和共享 token 维度下形成面向人体状态的 latent 表示。

C. 子集 Transformer 与 chunk 级专家

对当前可用模态子集 S ,模型将所有模态 token 拼接后输入跨模态 Transformer:

$$T_S = \text{Transformer}(\text{Concat}_{m \in S} Z_m). \quad (3)$$

随后, T_S 按模态切分为若干 modality chunks。每个 chunk 通过专家分支产生模态级预测 $\hat{y}_m$ 以及不确定性分数 s_m 。该设计的动机是:在缺失模态场景下,模型不应只依赖一个压缩后的全局特征,而应保留每个可用传感器的局部判断,再由融合机制进行动态整合。

D. 可靠性代理与专家-残差融合

本文使用 learned reliability proxy 对当前子集中的专家输出进行加权:

$$\alpha_m = \frac{\exp(-s_m/\tau)}{\sum_{j \in S} \exp(-s_j/\tau)}, \quad m \in S. \quad (4)$$

其中 α_m 是任务驱动的模式贡献权重,不代表经过物理标定的传感器可靠性。专家融合输出为 $\hat{y}_{exp} = \sum_{m \in S} \alpha_m \hat{y}_m$ 。同时,模型将各 chunk 的池化表示加权形成全局表示 z_S ,再经过融合残差分支持得到 $\hat{y}_{res}$ 。最终预测为:

$$\hat{y} = 0.5 \hat{y}_{exp} + 0.5 \hat{y}_{res}. \quad (5)$$

专家分支保留模态专属判断,残差分支建模跨模态互补关系,两者共同服务于随机传感器可用状态下的稳定感知。

E. Full-to-Subset Guidance

传统知识蒸馏多用于大模型到小模型或 teacher logits 到 student logits 的压缩学习 [25], [26]。本文中的 FSG 关注的是输入条件不对称:教师使用完整模态集合 $\mathcal{M}$,学生使用随机可用子集 S 。教师首先在完整模态条件下学习完整感知行为,随后固定教师,用输出、token、结构和融合行为约束学生:

$$\min_{\theta_S} \mathbb{E}_{(x,y)} \mathbb{E}_{S \sim q(S)} [\mathcal{L}_{task} + \lambda_o \mathcal{L}_{out} + \lambda_t \mathcal{L}_{tok} + \lambda_s \mathcal{L}_{str} + \lambda_r \mathcal{L}_{rel} + \lambda_u \mathcal{L}_{unc}]. \quad (6)$$

其中 $\mathcal{L}_{task}$ 是 HPE 的监督回归损失或 HAR 的交叉熵损失; $\mathcal{L}_{out}$ 对齐学生和教师输出; $\mathcal{L}_{tok}$ 对齐 body-token 表示; $\mathcal{L}_{str}$ 约束骨架或结构关系; $\mathcal{L}_{rel}$ 对齐融合权重; $\mathcal{L}_{unc}$ 用于稳定不确定性估计。本文不声称所有损失项在所有任务上均带来单调增益,而是将 FSG 作为完整模态行为到缺失模态学生的训练约束。

IV. 实验设置

A. 数据集与任务

本文在 MMFi 风格多模态人体感知数据上进行实验。HPE 使用 VK、Depth、LiDAR、mmWave 和 WiFi-CSI 五种输入,评估 31 种非空模态组合; HAR 使用 VK、Depth、LiDAR 和 mmWave 四种输入,评估 15 种非空模态组合。HPE 标签为 17 个人体 3D 关节点, HAR 标签为动作类别。除随机划分外,本文还报告 cross-subject 和 cross-scene 协议,以观察主体变化和场景变化下的泛化边界。

VK-RMD with Full-to-Subset Guidance

A two-part schematic: left, subset-conditioned expert fusion; right, full teacher-to-subset student losses.




Fig. 1. VK-RMD 框架。模型以 Visual Keypoints、Depth、LiDAR、mmWave 和 WiFi-CSI 为可用输入，通过模态专属编码器和投影层得到统一 body-token 表示；随机缺失模态学生在当前可用子集上进行 chunk 级专家预测和融合残差预测，并通过完整模态教师提供的 Full-to-Subset Guidance 学习完整感知行为。

Fig. 2. Missing-Modality Training and Evaluation Protocol




Fig. 2. 缺失模态训练与全子集测试协议。训练阶段随机采样可用模态子集，测试阶段覆盖所有非空组合，从而评估模型在动态传感器可用性下的稳定性。

B. 对比方法与指标

主要 baseline 采用 X-Fi 原论文表项，而不是异常复现实验中的偏离结果。HPE 使用 MPJPE 和 PA-MPJPE，单位为 mm，数值越低越好；HAR 使用 accuracy，单位为百分比，数值越高越好。为了更公平地分析缺失模态机制，本文还报告 Student-VK、Student-NV、uniform fusion、w/o distillation、缺失强度分组、leave-one-out、跨协议泛化、身份泄露探针和 L40 GPU 部署效率。

C. 实现细节

模型使用模态专属 backbone 提取不同传感器特征，并将各模态表示投影为 32 个 token，每个 token 维度为 512。训练 batch size 为 16。HPE 学生模型训练 100 个 epoch，HAR 学生模型训练 50 个 epoch；主要长训练中每个 epoch

最多使用 1000 个训练 batch。模型在随机模态子集上训练学生，并在完整模态教师约束下优化 FSG 目标。部署效率实验在 NVIDIA L40 GPU 上测量参数量、模型大小、延迟和 FPS，仅作为 GPU 推理成本分析，不代表边缘设备实测。

V. 结果与分析

A. 与 X-Fi 原论文表项的逐组合对比

表 I 和表 II 给出了与 X-Fi 原论文表项对齐的逐组合比较。本文不再只用平均值概括性能，而是按照单模态、双模态、三模态、四模态和五模态组合直接报告对应结果。这样可以观察每个传感器组合下 VK-RMD 的收益和不足。

在 HPE 中，VK-RMD 在绝大多数组合上优于 X-Fi 表项，尤其是包含 Depth 的组合表现明显稳定。例如，完整模态 V+D+L+R+W 下 MPJPE 从 83.7 mm 降至 50.2 mm，PA-MPJPE 从 47.6 mm 降至 33.5 mm。单模态 WiFi-CSI 仍然是困难输入，PA-MPJPE 略有退化，说明无线信号对细粒度 3D 姿态估计仍存在信息瓶颈。在 HAR 中，VK-RMD 在多数模态组合上显著提升，完整模态 V+D+L+R 的 accuracy 从 72.2% 提升至 96.6%。LiDAR 单模态在 HAR 中下降，表明动作识别更依赖 mmWave 和 Depth 等动态或几何信号。

B. FSG 缺失强度与关键模态分析

表 III 展示了随缺失数量增加的性能变化。随着可用模态减少，HPE 误差逐步上升，HAR accuracy 和 F1 逐步下降，这符合真实部署中传感器减少会降低信息量的预期。更重要的是，Student-VK 在严重缺失条件下仍保留可用性，而 Student-NV 在 HPE 中随着缺失加剧退化更快，说明 VK 结构输入对姿态估计仍然有稳定价值。

TABLE I

与 X-Fi 原论文表项对齐的 HPE 逐组合结果。MPJPE 和 PA-MPJPE 单位为 mm，数值越低越好；绿色向下箭头表示相对 X-Fi 提升，红色向上箭头表示退化。V=VISUAL KEYPOINTS, D=DEPTH, L=LiDAR, R=mmWave, W=WiFi-CSF。

模态	MPJPE↓			PA-MPJPE↓		
	X-Fi	VK-RMD	Δ	X-Fi	VK-RMD	Δ
V	93.9	92.7	↓ 1.2	60.3	42.6	↓ 17.7
D	101.8	53.9	↓ 47.9	48.4	35.6	↓ 12.8
L	167.1	140.1	↓ 27.0	103.2	93.5	↓ 9.7
R	127.4	115.0	↓ 12.4	69.8	58.1	↓ 11.7
W	225.6	222.1	↓ 3.5	105.3	110.2	↑ 4.9
V+D	86.1	51.7	↓ 34.4	48.1	34.3	↓ 13.8
V+L	93.0	73.2	↓ 19.8	59.7	41.9	↓ 17.8
V+R	88.8	68.9	↓ 19.9	57.3	38.9	↓ 18.4
V+W	93.0	88.1	↓ 4.9	59.5	42.3	↓ 17.2
D+L	102.5	53.0	↓ 49.5	48.4	35.4	↓ 13.0
D+R	98.0	52.3	↓ 45.7	47.3	34.6	↓ 12.7
D+W	101.8	53.5	↓ 48.3	48.1	35.5	↓ 12.6
L+R	109.8	97.5	↓ 12.3	63.4	55.1	↓ 8.3
L+W	159.5	134.2	↓ 25.3	102.7	93.2	↓ 9.5
R+W	117.2	108.5	↓ 8.7	62.7	57.3	↓ 5.4
V+D+L	84.8	51.1	↓ 33.7	48.2	34.2	↓ 14.0
V+D+R	83.4	50.5	↓ 32.9	47.3	33.5	↓ 13.8
V+D+W	85.3	51.6	↓ 33.7	48.1	34.3	↓ 13.8
V+L+R	88.4	66.1	↓ 22.3	57.2	38.8	↓ 18.4
V+L+W	93.0	70.7	↓ 22.3	59.7	41.8	↓ 17.9
V+R+W	88.5	66.7	↓ 21.8	57.1	38.8	↓ 18.3
D+L+R	96.0	51.9	↓ 44.1	47.3	34.5	↓ 12.8
D+L+W	102.0	52.9	↓ 49.1	48.1	35.4	↓ 12.7
D+R+W	97.0	52.1	↓ 44.9	47.1	34.6	↓ 12.5
L+R+W	107.4	94.2	↓ 13.2	63.1	55.1	↓ 8.0
V+D+L+R	83.5	50.2	↓ 33.3	47.6	33.4	↓ 14.2
V+D+L+W	86.0	51.0	↓ 35.0	48.2	34.2	↓ 14.0
V+D+R+W	84.0	50.4	↓ 33.6	47.6	33.5	↓ 14.1
V+L+R+W	88.6	64.2	↓ 24.4	57.1	38.8	↓ 18.3
D+L+R+W	97.6	51.8	↓ 45.8	47.4	34.5	↓ 12.9
V+D+L+R+W	83.7	50.2	↓ 33.5	47.6	33.5	↓ 14.1

表 IV 进一步分析关键模态。HPE 对 Depth 更敏感，移除 Depth 带来 14.1 mm MPJPE 增加；HAR 对 mmWave

TABLE II

与 X-Fi 原论文表项对齐的 HAR 逐组合结果。ACCURACY 单位为百分比，数值越高越好；绿色向上箭头表示相对 X-Fi 提升，红色向下箭头表示退化。
V=VISUAL KEYPOINTS, D=DEPTH, L=LiDAR, R=mmWave。

模态	X-Fi Acc.↑	VK-RMD Acc.↑	Δ Acc.
V	26.5	65.3	↑ 38.8
D	48.1	88.0	↑ 39.9
L	52.7	40.8	↓ 11.9
R	85.7	85.9	↑ 0.2
V+D	45.3	89.5	↑ 44.2
V+L	35.2	68.5	↑ 33.3
V+R	73.4	92.7	↑ 19.3
D+L	51.6	88.5	↑ 36.9
D+R	79.8	96.4	↑ 16.6
L+R	88.7	89.5	↑ 0.8
V+D+L	48.7	89.6	↑ 40.9
V+D+R	70.7	96.6	↑ 25.9
V+L+R	77.8	92.7	↑ 14.9
D+L+R	80.5	96.4	↑ 15.9
V+D+L+R	72.2	96.6	↑ 24.4

TABLE III

FSG 缺失强度结果。HPE 为 MPJPE/PA-MPJPE，单位 mm，越低越好；HAR 为 ACCURACY/F1，单位%，越高越好。VK 表示包含 VISUAL KEYPOINTS 的 STUDENT-VK，NV 表示完全非视觉 STUDENT-NV。

缺失数量	HPE↓				HAR↑			
	VK MPJPE	VK PA	NV MPJPE	NV PA	VK Acc.	VK F1	NV Acc.	NV F1
0	50.2	33.5	51.0	35.7	96.6	96.5	96.1	96.1
1	53.5	34.9	61.3	40.5	93.8	93.8	90.1	90.0
2	60.8	38.1	79.4	50.7	87.5	87.6	66.0	65.7
3	78.1	46.8	124.3	71.2	70.0	69.9	—	—
4	124.8	68.0	—	—	—	—	—	—

更敏感，移除 mmWave 带来 6.9% accuracy 下降。这说明 VK 不是唯一中心，Depth 和 mmWave 提供任务相关物理证据。本文更稳妥的结论是：VK 提供低外观结构线索，Depth/mmWave 等传感器提供互补物理证据，FSG 使模型在不同可用子集下学习这些证据的组合方式。

C. 跨协议泛化

表 V 显示，cross-subject 协议下 Student-VK 与 random split 接近，说明该框架具有一定主体泛化能力。相比之下，

cross-scene 下 HPE 平均 MPJPE 明显上升，说明缺失模态鲁棒性并不等于场景泛化鲁棒性。本文在主文中保留该结果，是为了明确方法边界：VK-RMD 更适合固定或校准过的多传感器部署环境，跨房间、跨布设和跨环境迁移仍需要进一步的域适应或传感器归一化机制。

D. 消融、可靠性权重与诊断分析

表 VI 表明，uniform fusion 在 HPE 和 HAR 中均弱于 VK-RMD，尤其 HAR 平均 accuracy 明显下降，说明动态




Fig. 3. HPE 和 HAR 主结果概览。该图用于辅助阅读逐组合表格，展示 Student-VK 与 Student-NV 在平均性能和完整模态性能上的整体趋势。

TABLE IV

LEAVE-ONE-OUT 关键模态分析。HPE 数值表示移除该模态后的误差增加量，HAR 数值表示移除该模态后的 ACCURACY/F1 下降量。

移除模态	HPE Δ MPJPE	HPE Δ PA	HAR Δ Acc.	HAR Δ F1
V	1.6	1.1	0.1	0.1
D	14.1	5.3	3.8	3.7
L	0.2	0.1	0.0	0.0
R	0.9	0.7	6.9	7.1
W	0.1	-0.0	—	—




Fig. 4. 不同缺失强度下的性能趋势。随着缺失模态数量增加，HPE 误差和 HAR 错误率整体上升，说明全子集压力测试能够揭示完整模态评估无法暴露的部署风险。

权重对缺失模态组合是必要的。w/o distillation 在 HPE 中数值更强，而在 HAR 中弱于 VK-RMD，因此本文不把 FSG 写成所有任务上唯一或必然的收益来源。更合理的解释是：HPE 中强监督标签已经足够稳定，FSG 主要提供完整模态行为约束；HAR 中动作类别更依赖跨模态互补，FSG 的辅助收益更明显。图 5 和图 6 进一步展示了 learned reliability proxy 的行为，但本文谨慎地将其解释为任务贡献代理，而不是物理可靠性传感器。




Fig. 5. 不同模态组合下的 reliability proxy 权重。该图只说明模型会根据当前可用模态调整任务贡献权重，不代表物理传感器可靠性的严格标定。

Reliability-aware proxy under synthetic modality corruption




Fig. 6. 合成模态扰动下的 reliability proxy 诊断。该实验用于观察权重对扰动的响应趋势，不能解释为因果证明或传感器质量标定。

Ablation Analysis of VK-RMD




Fig. 7. 公平基线和核心消融的概览。Uniform fusion 与 w/o distillation 用于解释动态融合和 FSG 在不同任务中的作用边界。

E. 身份泄露探针与低视觉暴露分析

表 VII 显示，VK 的主体识别准确率显著低于脱敏 RGB，说明将在线输入从图像改为结构关键点可以降低下游模型中的身份外观可预测性。然而，VK 仍高于随机猜测，说明骨架几何、步态和动作习惯仍可能泄露个体信息。因此，本文使用“低视觉暴露”和“privacy-friendly”表述，而不

TABLE V

跨协议泛化结果。HPE 为平均/完整模态 MPJPE，单位 MM；HAR 为平均/完整模态 ACCURACY，单位%。CROSS-SCENE 结果显示场景变化仍是主要挑战。

协议	模型	HPE Avg.↓	HPE Full↓	HAR Avg.↑	HAR Full↑
random split	VK-RMD VK	75.18	50.17	85.15	96.56
random split	VK-RMD NV	84.68	51.03	80.62	96.12
cross-subject	VK-RMD VK	78.57	49.88	85.30	96.12
cross-subject	VK-RMD NV	90.74	52.45	81.26	95.70
cross-scene	VK-RMD VK	142.02	71.71	80.61	95.25
cross-scene	VK-RMD NV	153.89	78.96	76.70	95.41

TABLE VI

核心消融结果。HPE 数值为平均/完整模态 MPJPE，HAR 数值为平均/完整模态 ACCURACY。

任务	设置	平均	完整模态
HPE	VK-RMD	75.18	50.17
HPE	w/o distillation	72.68	48.83
HPE	uniform fusion	82.77	52.28
HAR	VK-RMD	85.15	96.56
HAR	w/o distillation	82.86	95.99
HAR	uniform fusion	67.46	95.39

TABLE VII

主体识别探针。数值为主体 ID 分类 ACCURACY，越低表示身份可预测性越弱。该实验只评估下游特征中的身份泄露风险，不代表形式化安全承诺。

输入表示	主体识别准确率	说明
随机猜测	2.50%	40 个主体
脱敏 RGB	67.53%	仍包含体型、服饰和背景线索
Visual Keypoints	15.43%	显著降低外观暴露，但不为零

TABLE VIII

L40 GPU 上的代表性推理成本。延迟为 BATCH SIZE 1 的平均值；该表只报告 GPU 推理成本，不代表边缘设备实测。

任务	模态	参数量	模型大小	延迟
HPE	V	45.94M	175.39 MB	8.0 ms
HPE	V+D	45.94M	175.39 MB	21.4 ms
HPE	V+D+L+R+W	45.94M	175.39 MB	3375.7 ms
HAR	V	24.38M	93.06 MB	15.9 ms
HAR	V+D	24.38M	93.06 MB	36.0 ms
HAR	V+D+L+R	24.38M	93.06 MB	3321.3 ms

使用身份不可恢复或密码学安全相关表述。

F. L40 GPU 推理成本

表 VIII 说明，轻量模态组合具有较低延迟，而包含点云和雷达处理的完整模态组合成本明显更高。该结果支持本文的部署动机：真实系统需要根据传感器可用性、成本和




Fig. 8. VK 结构语义锚点诊断。该图用于观察 VK 关节扰动、关节顺序破坏和样本错配对性能的影响。它支持 VK 具有结构语义作用，但不证明 VK 是唯一中心模态。

任务需求动态选择模态组合，而不是始终依赖最重的完整输入。

VI. 讨论

关于 VK 来源。本文不要求 VK 必须由在线 RGB 提取。更准确地说，VK 是上游人体姿态估计模块的结构化输出，可以来自离线 RGB 处理、前端脱敏设备、RGB-D、Depth、Thermal/IR、LiDAR 或 mmWave 等能够估计人体关键点的传感器系统。不同上游设备的 VK 精度并不相同，本文实验使用已对齐的 VK 表示评估下游感知框架，而不比较不同 VK 生成器的精度。若未来使用 mmWave 或其他非视觉信号生成 VK，需要单独验证上游关键点误差及其对下游 HPE/HAR 的影响。

关于 mmWave 替代 RGB 生成 VK 的可行性。已有非视觉人体姿态估计研究表明，毫米波雷达、WiFi-CSI 和 Depth 等信号可以估计人体骨架或关键点 [12]–[15]。因此，从非 RGB 传感器生成 VK 作为前端结构表示具有可行性基础。但本文尚未完成 mmWave-to-VK 上游生成实验，也没有报告其精度或对下游任务的影响。因此，该方向在本文中只作为待验证扩展，不作为主实验结论。

关于 FSG 与蒸馏。FSG 与传统知识蒸馏共享 teacher-student 形式，但关键差异在于监督目标来自完整模态到缺失模态，而不是大模型到小模型。它不是为了压缩参数，而是为了让学生在任意子集输入下学习完整模态系统的判断方式。消融结果也说明 FSG 的效果具有任务依赖性：在 HPE 中不应声称蒸馏全面提升，在 HAR 中则提供更明显的稳定收益。

关于跨场景限制。Cross-scene HPE 结果明显弱于 random split 和 cross-subject, 说明不同房间、不同布设和不同环境反射条件仍会影响多模态人体感知。本文的贡献是低视觉暴露与缺失模态鲁棒学习, 而不是彻底解决跨场景泛化。未来可以结合域适应、传感器校准、环境归一化和少样本场景适配进一步提升跨场景性能。

VII. 结论

本文提出 VK-RMD, 一种面向低视觉暴露与缺失模态鲁棒的多模态人体感知框架。该框架使用 Visual Keypoints 替代在线原始 RGB, 降低下游身份外观可预测性; 通过 Full-to-Subset Guidance 将完整模态教师的感知行为迁移到随机缺失模态学生; 并利用 chunk 级专家分支和融合残差分支处理动态传感器可用性。实验覆盖 HPE 的 31 种模态组合、HAR 的 15 种模态组合以及 random split、cross-subject 和 cross-scene 协议。结果表明, VK-RMD 在多数模态组合上优于 X-Fi 原论文表项, 并在低视觉暴露、随机模态缺失和跨协议评估中表现出较强适应性。与此同时, 本文也明确指出 VK 不是形式化匿名表示, cross-scene 仍是主要挑战, mmWave-to-VK 等非视觉 VK 生成路径仍需后续验证。

数据与代码可用性

本文使用的实验结果来自本地工程目录中的已有输出文件和生成表格。MMFi 数据集及 X-Fi baseline 的获取方式应遵循原始数据集和原论文发布协议。本文当前稿件未提供公开代码仓库链接, 后续投稿版本可补充训练脚本、评估脚本、表格生成脚本及随机种子设置。

REFERENCES

- [1] X. Yang, Y. Wang, and collaborators, "X-Fi: A modality-invariant foundation model for multimodal human sensing," arXiv preprint, 2024.
- [2] Y. Yang, Z. Huang, and collaborators, "MM-Fi: Multi-modal non-intrusive 4D human dataset for versatile wireless sensing," in *Proc. NeurIPS Datasets and Benchmarks*, 2023.
- [3] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime multi-person 2D pose estimation using part affinity fields," *IEEE TPAMI*, vol. 43, no. 1, pp. 172–186, 2021.
- [4] S. Yan, Y. Xiong, and D. Lin, "Spatial temporal graph convolutional networks for skeleton-based action recognition," in *Proc. AAAI*, 2018.
- [5] K. Sun, B. Xiao, D. Liu, and J. Wang, "Deep high-resolution representation learning for human pose estimation," in *Proc. CVPR*, 2019.
- [6] H.-S. Fang, S. Xie, Y.-W. Tai, and C. Lu, "RMPE: Regional multi-person pose estimation," in *Proc. ICCV*, 2017.
- [7] Y. Xu, J. Zhang, Q. Zhang, and D. Tao, "ViTPose: Simple vision transformer baselines for human pose estimation," in *Proc. NeurIPS*, 2022.
- [8] A. Vaswani et al., "Attention is all you need," in *Proc. NeurIPS*, 2017.
- [9] J. Shotton et al., "Real-time human pose recognition in parts from single depth images," in *Proc. CVPR*, 2011.
- [10] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep learning on point sets for 3D classification and segmentation," in *Proc. CVPR*, 2017.
- [11] H. Zhao, L. Jiang, J. Jia, P. Torr, and V. Koltun, "Point Transformer," in *Proc. ICCV*, 2021.
- [12] A. Sengupta, F. Jin, R. Zhang, and S. Cao, "mm-Pose: Real-time human skeletal posture estimation using mmWave radars and CNNs," *IEEE Sensors Journal*, vol. 20, no. 17, pp. 10032–10044, 2020.
- [13] S. An and U. Y. Ogras, "mRI: Multi-modal 3D human pose estimation dataset using mmWave, RGB-D, and inertial sensors," in *Proc. NeurIPS Datasets and Benchmarks*, 2022.
- [14] Y. Zhang, J. Li, and collaborators, "VirTeach: mmWave radar point-cloud-based pose estimation with virtual data as a teacher," *IEEE Internet of Things Journal*, 2024.
- [15] F. Wang, S. Zhou, and collaborators, "MetaFi++: WiFi-enabled transformer-based human pose estimation for metaverse avatar simulation," *IEEE Internet of Things Journal*, 2023.
- [16] J. Wang, Q. Gao, and H. Wang, "Device-free wireless sensing for human activity recognition: A survey," *IEEE Communications Surveys & Tutorials*, vol. 19, no. 3, pp. 1417–1442, 2017.
- [17] H. Wang, Y. Chen, and collaborators, "Multimodal human activity recognition using contrastive fusion," *IEEE Internet of Things Journal*, 2025.
- [18] A. Shrestha and F. Xing, "Device-free human activity recognition: A systematic literature review," *IEEE Internet of Things Journal*, 2024.
- [19] L. Zhang, M. Liu, and collaborators, "AdaPose: Toward cross-site device-free human pose estimation," *IEEE Internet of Things Journal*, 2024.
- [20] Z. Li, X. Chen, and collaborators, "Robust WiFi sensing-based human pose estimation," *IEEE Internet of Things Journal*, 2025.
- [21] C. Chen, R. Jafari, and N. Kehtarnavaz, "Improving human action recognition using fusion of depth camera and inertial sensors," *IEEE Transactions on Human-Machine Systems*, vol. 45, no. 1, pp. 51–61, 2015.
- [22] D. Ma, S. Li, and collaborators, "Deep multimodal learning with missing modality: A survey," arXiv preprint, 2024.
- [23] M. Memmel, H. Zhao, and collaborators, "Towards good practices for missing modality robust action recognition," in *Proc. AAAI*, 2023.
- [24] A. Neverova, C. Wolf, G. Taylor, and F. Nebout, "ModDrop: Adaptive multi-modal gesture recognition," *IEEE TPAMI*, vol. 38, no. 8, pp. 1692–1706, 2016.
- [25] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," arXiv preprint arXiv:1503.02531, 2015.
- [26] A. Romero et al., "FitNets: Hints for thin deep nets," in *Proc. ICLR*, 2015.
- [27] V. Vapnik and A. Vashist, "A new learning paradigm: Learning using privileged information," *Neural Networks*, vol. 22, no. 5–6, pp. 544–557, 2009.
- [28] A. Radford et al., "Learning transferable visual models from natural language supervision," in *Proc. ICML*, 2021.
- [29] A. Jaegle et al., "Perceiver IO: A general architecture for structured inputs and outputs," in *Proc. ICLR*, 2022.
- [30] C. Hinojosa, J. C. Niebles, and H. Arguella, "Learning privacy-preserving optics for human pose estimation," in *Proc. ICCV*, 2021.
- [31] M. Ryoo, K. Rothrock, and L. Matthies, "Pooled motion features for first-person videos," in *Proc. CVPR*, 2015.
- [32] A. R. Beresford and F. Stajano, "Location privacy in pervasive computing," *IEEE Pervasive Computing*, vol. 2, no. 1, pp. 46–55, 2003.
- [33] M. Saini, P. Atrey, S. Mehrotra, and M. Kankanhalli, "Privacy modeling for video data publication," in *Proc. ICME*, 2010.
- [34] A. Toshev and C. Szegedy, "DeepPose: Human pose estimation via deep neural networks," in *Proc. CVPR*, 2014.
- [35] L. Xia, C.-C. Chen, and J. Aggarwal, "View invariant human action recognition using histograms of 3D joints," in *Proc. CVPR Workshops*, 2012.
- [36] Y. Zhou and O. Tuzel, "VoxelNet: End-to-end learning for point cloud based 3D object detection," in *Proc. CVPR*, 2018.
- [37] J. Pegoraro and M. Rossi, "Real-time people tracking and identification from sparse mm-wave radar point-clouds," *IEEE Access*, vol. 9, pp. 78504–78520, 2021.
- [38] Y. Ma, G. Zhou, and S. Wang, "WiFi sensing with channel state information: A survey," *ACM Computing Surveys*, vol. 52, no. 3, pp. 1–36, 2019.
- [39] Y. Ganin et al., "Domain-adversarial training of neural networks," *JMLR*, vol. 17, no. 59, pp. 1–35, 2016.
- [40] A. Kendall and Y. Gal, "What uncertainties do we need in Bayesian deep learning for computer vision?" in *Proc. NeurIPS*, 2017.
- [41] D. Lahat, T. Adali, and C. Jutten, "Multimodal data fusion: An overview of methods, challenges, and prospects," *Proceedings of the IEEE*, vol. 103, no. 9, pp. 1449–1477, 2015.
- [42] M. A. Razzaque, M. Milojevic-Jevric, A. Palade, and S. Clarke, "Middleware for Internet of Things: A survey," *IEEE Internet of Things Journal*, vol. 3, no. 1, pp. 70–95, 2016.
- [43] L. Catarinucci et al., "An IoT-aware architecture for smart healthcare systems," *IEEE Internet of Things Journal*, vol. 2, no. 6, pp. 515–526, 2015.
- [44] O. D. Lara and M. A. Labrador, "A survey on human activity recognition using wearable sensors," *IEEE Communications Surveys & Tutorials*, vol. 15, no. 3, pp. 1192–1209, 2013.
- [45] Y. Chen and Y. Xue, "A deep learning approach to human activity recognition based on single accelerometer," in *Proc. IEEE SMC*, 2015.

- [46] S. Poria, E. Cambria, R. Bajpai, and A. Hussain, "A review of affective computing: From unimodal analysis to multimodal fusion," *Information Fusion*, vol. 37, pp. 98–125, 2017.
- [47] Y. Aytar, C. Vondrick, and A. Torralba, "See, hear, and read: Deep aligned representations," arXiv preprint arXiv:1706.00932, 2017.
- [48] E. R. Chan, C. Z. Lin, M. A. Chan, and G. Wetzstein, "Efficient geometry-aware 3D generative adversarial networks," in *Proc. CVPR*, 2022.
- [49] D. Tome, C. Russell, and L. Agapito, "Lifting from the deep: Convolutional 3D pose estimation from a single image," in *Proc. CVPR*, 2017.
- [50] S. Palipana, D. Rojas, P. Agrawal, and D. Pesch, "FallDeFi: Ubiquitous fall detection using commodity Wi-Fi devices," *Proceedings of the ACM IMWUT*, vol. 1, no. 4, pp. 1–25, 2018.
- [51] F. Adib, Z. Kabelac, D. Katabi, and R. C. Miller, "3D tracking via body radio reflections," in *Proc. NSDI*, 2014.