

VK-RMD: 一种 XXXX

Eagle

Abstract—人体感知作为智能空间、人机交互和具身智能中的基础感知能力，逐渐成为人类行为理解与智能空间决策的重要技术支撑。现有多模态人体感知方法通常建立在传感器稳定部署、模型部署场景稳定等较理想条件上。以 RGB 为代表的视觉信号在人体感知中起到至关重要的作用，然而，RGB 在携带丰富人体信息的同时，还携带大量的个人身份信息，在部署上存在明显的视觉暴露风险。其次，IoT 传感器在长期运行中可能因遮挡或设备损坏等原因而随机不可用，导致依赖完整模态或固定模态组合的模型性能退化，更进一步，人体感知现有技术在面对跨主体、跨场景条件下的泛化能力仍然有限。为此，本文提出 VK-RMD，一种面向低视觉暴露、随机传感器失效和开放场景泛化的多模态人体感知框架。VK-RMD 使用视觉关键点（Visual Keypoints, VK）作为输入，VK 结构可以由多种低外观或前端敏感的人体姿态估计模块生成。实验结果显示 VK 将主体识别准确率从脱敏 RGB 的 67.53% 降至 15.43%，表明 VK 可以显著降低下游感知中的身份预测。仅降低视觉暴露不能解决真实部署中的全部问题，真实部署中必须面临设备随机崩坏，受实主体不定和跨场景泛化等难题，基于此，本文在部署中采用模态知识蒸馏技术，利用完整多模态数据训练教师模型，而使用随机缺失模态数据训练学生模型，从而使得学生模型获得更优的泛化性能和跨场景泛化能力。本文在 MMFi 数据集的 cross-random-split、cross-subject 和 cross-scene 三类协议下系统验证视觉关键点的泛化能力，并在人体姿态估计和人体活动识别任务上进行全子集评估，覆盖 HPE 的 31 种模态组合和 HAR 的 15 种模态组合。实验结果表明，VK-RMD 在三类 cross 协议下均优于已有 X-Fi 基线，并在随机模态缺失、低视觉暴露和跨场景泛化条件下表现出更强鲁棒性，本文方法能够在降低视觉暴露的同时，提高模型面对动态传感器可用性的适应能力。VK-RMD 在完整模态设置下，HPE 的 MPJPE 从 83.7 mm 降至 50.2 mm，HAR 的准确率从 72.2% 提升至 96.6%，表明 VK 可以显著降低下游感知中的身份预测，同时在跨主体和跨场景评估中表现出不错的泛化能力。总而言之，VK-RMD 在降低视觉暴露、适应随机模态缺失和提升跨协议泛化方面表现出稳定优势，为开放 IoT 场景中的鲁棒多模态人体感知提供了一种有效方案。

Index Terms—多模态感知，人体姿态估计，人体活动识别，缺失模态训练，模态知识蒸馏。

I. 引言

人体感知是智能空间、辅助生活、人机交互、公共安全和具身智能中的基础能力。它的目标是从环境中的多源观测信号中恢复人体状态，包括人体姿态、运动过程和动作语义。受益于算力的提升和传感器的精度提升，多模态感知精度和技术已取得很多显著进展，并被广泛应用于智能空间、辅助生活、人机交互、公共安全和具身智能等领域。

目前，人体感知系统通常依赖 RGB、Depth、LiDAR、mmWave 和 WiFi-CSI 等多源传感判别人体姿态和活动语义。随着多模态感知模型的发展，不同传感器之间的互补信息已经被广泛用于提升人体姿态估计和人体活动识别性能。然而，当这些系统从实验环境走向开放 IoT 部署时，关键挑战不再只是如何融合更多传感器，还涉及个人隐私安全，以及如何在观测受限且动态变化的条件下保持高可靠感知。因此，未来人体感知识别的发展需要充分考虑视觉信息的暴露问题和模型跨场景跨主体的泛化能力。

已有研究已经注意到原始 RGB 在人体感知中的隐私风险，并尝试通过减少视觉信息进入下游模型来降低身份泄露。一类方法直接移除摄像头，转向 WiFi、毫米波雷达、LiDAR 或 Depth 等非 RGB 传感器；例如，基于 WiFi-CSI 的活动识别、基于毫米波雷达的人体姿态估计，等非视觉人体感知方法，旨在避免采集人脸、衣着等显式视觉信息，从源头降低身份暴露风险。然而，完全脱离视觉信息也会削弱模型对人体关节结构和动作上下文的感知能力，且非视觉传感器本身受到空间分辨率、环境反射等因素限制，难以在复杂场景中稳定支撑高精度人体感知。另一类方法将 RGB 图像转化为人体骨架，做单模态的姿态估计和活动识别。这类方法保留了人体关节拓扑和姿态几何信息，同时减少了原始图像中的身份外观暴露。然而，基于骨架的单模态方案很难有适应跨场景的泛化能力，未来人体感知技术的发展需要能充分利用不同模态优势的多模态方法。同时，在真实的场景部署 IoT 时，人体感知系统面对的观测条件更加复杂。不同房间布局、主体差异和环境反射等会造成明显的跨场景分布变化，因此模型需要具备 cross-scene 泛化能力；同时，传感器可能因遮挡、噪声或设备损坏而随机不可用，模态缺失也成为长期运行中的常态。因此，作者思考是否可以设计一种不依赖 RGB 视觉信号，降低隐私暴露的同时又可以利用 RGB 视觉信息和其他模态数据信息进行融合，同时在部署端进行不同模态间蒸馏以获得模型跨场景、跨主体，又能应对缺失模态时保持高识别率的方案。

为实现低视觉暴露和缺失模态鲁棒的人体感知，本文希望设计一个能够动态使用跨场景和跨主体泛化能力的模型。首先，考虑到真实部署中模态数量可能变化，模型需要支持任意可用模态子集输入。其次，考虑到不同模态具有不同物理含义，本文采用模态专属编码器分别提取 Visual Keypoints、Depth、LiDAR、mmWave 和 WiFi-CSI 的特征。最后，为了在融合过程中保留每个模态的差异性信息，本文将各模态特征划分为 modality chunks，并设计专家分支和融合残差分支，同时保留模态专属判断和跨模态互补信息。这样，模型不仅能够处理动态模态输入，还能在随机缺失模态训练中学习不同传感器之间的互补关系，从而优于简单特征拼接、平均融合或固定模态输入方法。

基于此，本文提出一种新的低视觉暴露缺失模态人体感知框架 VK-RMD。VK-RMD 使用 Visual Keypoints 作为下游结构输入，而不是在线使用原始 RGB。Visual Keypoints 可以来自任何能够提供人体 17 个骨架关键点的隐私友好设备；如果由 RGB 获取，也可通过离线关键点模型完成，原始 RGB 不进入在线感知模型。如图所示，VK-RMD 包含一组模态专属编码器，用于提取各模态的专属特征，并将其投影到统一的 body-token 空间。对于 Visual Keypoints 分支，模型首先对 17 个关键点进行坐标归一化和关节级嵌入，再结合骨架拓扑关系形成结构化人体 token。对于 Depth、LiDAR、mmWave 和 WiFi-CSI 分支，模型使用对应的传感器编码器提取物理模态特征，并通过投影层映射到相同维度的 body-token 表示。对于不同传感器组合，系统只激活当前可用模态的编码器，获得对应 modality chunks。

稿件接收日期占位；修改日期占位。
作者单位与地址占位。
通信作者：姓名占位。