

VK-RMD: 面向缺失模态多模态人体感知的低外观结构 Token 化与子集投影一致性学习

Eagle

Abstract—人体感知作为智能空间、人机交互和具身智能中的基础感知能力, 逐渐成为人类行为理解与智能空间决策的重要技术支撑。现有多模态人体感知方法通常建立在传感器稳定部署, 模型部署场景稳定等较理想条件上。以 RGB 为代表的视觉信号在人体感知中起到至关重要的作用, 然而, RGB 在携带丰富人体信息的同时, 还携带大量的个人身份信息, 在部署上存在明显的视觉暴露风险。其次, IoT 传感器在长期运行中可能因遮挡或设备损坏等原因而随机不可用, 导致依赖完整模态或固定模态组合的模型性能退化, 更进一步, 人体感知现有技术在面对跨主体、跨场景条件下的泛化能力仍然有限。为此, 本文提出 VK-RMD, 一种面向低视觉暴露、随机传感器失效和跨协议评估的多模态人体感知框架。VK-RMD 使用视觉关键点 (Visual Keypoints, VK) 作为输入, VK 结构可以由多种低外观或前端脱敏的人体姿态估计模块生成。实验结果显示 VK 将主体识别准确率从脱敏 RGB 的 67.53% 降至 15.43%, 表明 VK 可以显著降低下游感知中的身份预测。仅降低视觉暴露不能解决真实部署中的全部问题, 真实部署中还必须面对设备随机失效、受试主体变化和场景迁移等难题, 基于此, 本文使用完整多模态数据训练教师模型, 而使用随机缺失模态数据训练学生模型, 并提出子集投影的结构与融合一致性目标 (Subset-Projected Structural and Fusion Consistency, SP-SFC): 将教师的任务响应、人体结构、token 表示和融合行为条件化到学生当前可见子集, 以缩小完整观测和随机缺失观测之间的行为差距。针对动态子集引起的模态支配冲突, 本文进一步以同一任务不确定性代理耦合 chunk 级专家读出和全局融合 token 读出, 从而同时保留模态专属证据与跨模态互补信息。本文在 MMFi 数据集的 cross-random-split、cross-subject 和 cross-scene 三类协议下系统验证视觉关键点的泛化能力, 并在人体姿态估计和人体活动识别任务上进行全子集评估, 覆盖 HPE 的 31 种模态组合和 HAR 的 15 种模态组合。实验结果表明, VK-RMD 在随机划分和跨主体协议下保持稳定性能, 并在跨场景协议中揭示了环境迁移带来的明显性能边界; 在随机模态缺失和低视觉暴露条件下, 本文方法能够在降低视觉暴露的同时, 提高模型面对动态传感器可用性的适应能力。VK-RMD 在完整模态设置下将 HPE 的 MPJPE 从 83.7 mm 降至 50.2 mm, 并将 HAR 的准确率从 72.2% 提升至 96.6%; 配对边际分析进一步显示, 加入 VK 后 HPE 的 15/15 个匹配子集和 HAR 的 7/7 个匹配子集均得到改善。跨主体性能相对稳定, 而 cross-scene HPE 的明显退化说明场景迁移仍是未解决边界。总而言之, VK-RMD 在降低视觉暴露和适应随机模态缺失方面表现出稳定优势, 并通过跨协议评估明确其部署边界, 为传感器可用性动态变化的 IoT 场景提供了一种可验证的多模态人体感知方案。

Index Terms—多模态感知, 人体姿态估计, 人体活动识别, 缺失模态学习, 低视觉暴露, 子集投影一致性。

I. 引言

人体感知是智能空间、辅助生活、人机交互、公共安全和具身智能中的基础能力。它的目标是从环境中的多源观测信号中恢复人体状态, 包括人体姿态、运动过程和动作语义。受益于计算能力和传感器精度的持续提升, 多模态人体感知已取得显著进展, 并被广泛应用于智能空间、辅助生活、人机交互、公共安全和具身智能等领域 [1], [2]。

目前, 人体感知系统通常依赖 RGB、Depth、LiDAR、mmWave 和 WiFi-CSI 等多源传感判别人体姿态和活动语

义。随着多模态感知模型的发展, 不同传感器之间的互补信息已经被广泛用于提升人体姿态估计和人体活动识别性能。然而, 当这些系统从实验环境走向开放 IoT 部署时, 关键挑战不再只是如何融合更多传感器, 还包括身份信息暴露, 以及如何在观测受限且动态变化的条件下保持可靠感知。因此, 人体感知方法还需要同时考虑视觉信息暴露、传感器可用性变化以及跨主体和跨场景分布迁移。

已有研究已经注意到原始 RGB 在人体感知中的隐私风险, 并尝试通过减少视觉信息进入下游模型来降低身份泄露。一类方法直接移除摄像头, 转向 WiFi、毫米波雷达、LiDAR 或 Depth 等非 RGB 传感器; 例如, 基于 WiFi-CSI 的活动识别和基于毫米波雷达的人体姿态估计等非视觉人体感知方法 [3]–[6], 旨在避免采集人脸、衣着等显式视觉信息, 从源头降低身份暴露风险。然而, 完全脱离视觉信息也会削弱模型对人体关节结构和动作上下文的感知能力, 且非视觉传感器本身受到空间分辨率、环境反射等因素限制, 难以在复杂场景中稳定支撑高精度人体感知。另一类方法将 RGB 图像转化为人体骨架, 做单模态的姿态估计和活动识别 [7]–[10]。这类方法保留了人体关节拓扑和姿态几何信息, 同时减少了原始图像中的身份外观暴露。然而, 单模态骨架方案无法充分利用几何、雷达和无线观测的互补信息, 也不能单独消除场景迁移带来的分布偏移, 因此仍需要能够组织不同传感器证据的多模态方法。同时, 在真实 IoT 部署中, 人体感知系统面对的观测条件更加复杂。不同房间布局、主体差异和环境反射等会造成明显的跨场景分布变化, 因此模型的 cross-scene 泛化能力需要被明确评估; 同时, 传感器可能因遮挡、噪声或设备损坏而随机不可用, 模态缺失也成为长期运行中的常态 [11]–[14]。由此产生本文的核心科学问题: 在在线推理不依赖原始 RGB、且传感器可能任意缺失时, 如何利用低外观人体结构接口组织异构传感器证据, 并使当前有限模态子集尽可能维持完整观测条件下的 HPE 与 HAR 行为? 该问题同时包含视觉暴露、观测条件不对称和动态证据组织三层矛盾, 不能由简单替换输入、普通 modality dropout 或固定融合单独解决。

为实现低视觉暴露和缺失模态鲁棒的人体感知, 本文希望设计一个能够适应动态传感器可用性, 并明确刻画跨主体和跨场景泛化边界的模型。首先, 考虑到真实部署中模态数量可能变化, 模型需要支持任意可用模态子集输入。其次, 考虑到不同模态具有不同物理含义, 本文采用模态专属编码器分别提取 Visual Keypoints、Depth、LiDAR、mmWave 和 WiFi-CSI 的特征。最后, 为了在融合过程中保留每个模态的差异性信息, 本文将各模态特征划分为 modality chunks, 并设计专家分支和全局融合 token 读出, 同时保留模态专属判断和跨模态互补信息。这样, 模型不仅能够处理动态模态输入, 还能在随机缺失模态训练中学习不同传感器之间的互补关系, 从而优于简单特征拼接、平均融合或固定模态输入方法。

基于此, 本文提出一种新的低视觉暴露缺失模态人体感知框架 VK-RMD。VK-RMD 使用 Visual Keypoints 作为下游结构输入, 而不是在线使用原始 RGB。Visual Keypoints 在本文中被定义为上游模块提供的 17 点结构接口, 而不是某一种硬件的原始输出。当前主实验使用 MMFi 中与其他传感器同步的关键点数据; 如果由 RGB 获取, 可通过离线或受控前端关键点模型完成, 使原始 RGB 不进入在线下游感知模型。Depth/mmWave 来源的 VK 仅作为后文轻量可行性分析, 本文不据此假设任意设备都能提供同等精度的关键点。如图所示, VK-RMD 包含一组模态专属编码器, 用于提取各模态的专属特征, 并将其投影到统一的 body-token 空间。对于 Visual Keypoints 分支, 模型首先对 17 个关键点进行坐标归一化和关节级嵌入, 再结合骨架拓扑关系形成结构化人体 token。对于 Depth、LiDAR、mmWave 和 WiFi-CSI 分支, 模型使用对应的传感器编码器提取物理模态特征, 并通过投影层映射到相同维度的 body-token 表示。对于不同传感器组合, 系统只激活当前可用模态的编码器, 获得对应 modality chunks。随后, 跨模态 Transformer 学习当前模态子集中的交互关系。每个 chunk 一方面通过专家分支生成模态级预测, 另一方面通过全局融合 token 读出形成子集级预测。

为了进一步提升随机缺失场景下的稳定性, 本文采用完整观测教师与随机子集学生的 Full-to-Subset 训练关系。鉴于完整到不完整观测的蒸馏思想已有研究, 本文不将该关系本身作为独立创新, 而是在其上提出子集投影的结构与融合一致性目标 SP-SFC。具体而言, 完整模态教师学习所有传感器可用时的感知行为; 随机缺失模态学生在不同子集下学习教师的任务响应和 token 表示, 并将教师的完整融合分布截取到当前可见模态后重新归一, 以此监督学生的子集融合行为。HPE 进一步加入骨架结构一致性, HAR 使用温度化类别响应一致性; 两个任务均以模态专家误差约束 log-variance, 使预测质量、子集贡献权重和教师条件分布形成闭环。本文在 MMFi 数据集上的 HPE 和 HAR 任务中进行验证, 覆盖 HPE 的 31 种模态组合和 HAR 的 15 种模态组合。实验结果显示, VK-RMD 在完整模态设置下将 HPE 的 MPJPE 从 83.7 mm 降至 50.2 mm, 将 HAR 准确率从 72.2% 提升至 96.6%。

主要贡献总结如下。第一, 本文提出 VK-RMD, 一种面向低视觉暴露人体感知的多模态框架, 使用 Visual Keypoints 完全替代在线原始 RGB, 在降低身份外观暴露的同时保留人体结构信息。第二, 本文提出 SP-SFC, 将完整模态教师的任务响应、人体结构、token 表示及融合行为投影到学生当前可见子集, 并通过专家不确定性把模态级预测质量与子集级证据分配联系起来, 从而具体解决完整观测知识不能直接复制到随机缺失观测的问题。第三, 本文设计由同一任务不确定性代理耦合的 chunk 级专家读出与全局融合 token 读出机制, 在动态模态组合中同时保留模态专属证据和跨模态互补信息; 并通过 VK 配对边际贡献、HPE 的 31 种组合、HAR 的 15 种组合以及 cross-random-split、cross-subject 和 cross-scene 协议系统验证 VK-RMD 的效用与边界。

II. 相关工作

A. 人体感知

人体感知是智能空间、人机交互和具身智能中的基础能力, 其目标是从环境中的感知信号中恢复人体姿态、动作和行为状态。视觉姿态估计、骨架动作识别以及 Transformer

表示学习已经显著提升了人体结构与动作建模能力 [7]–[10], [15]。然而, RGB 信号在提供强感知能力的同时, 也直接记录面部、衣着、体型和背景等身份相关信息, 使其在家庭、医院和办公空间等隐私敏感场景中的部署受到限制。

为了减少对原始 RGB 的依赖, 研究者开始探索更加适合实际部署的替代感知信号。Depth、LiDAR、毫米波雷达和 WiFi-CSI 分别从空间几何、点云反射、雷达回波和无线信道扰动中捕获人体信息 [16]–[21]; 骨架和关键点则将密集视觉外观压缩为结构化关节信息。上述表示减少了对纹理和背景的依赖, 但其物理含义、噪声模式和空间分辨率差异显著, 单一模态难以稳定覆盖复杂场景。

因此, 当前人体感知研究逐渐从单一高质量输入转向多传感器协同建模 [22]–[24]。多模态方法能够结合几何、无线、雷达和结构化人体表示, 但许多方法仍默认传感器组合固定、部署场景稳定且输入完整。在真实 IoT 场景中, 遮挡、设备故障、带宽限制和环境变化会同时引起模态缺失与分布迁移; 模型因而需要在完整模态性能之外, 明确评估动态可用性和跨协议泛化。

B. 动态模态与缺失模态学习

真实多传感器系统很难保证所有模态始终可用。遮挡、设备故障、带宽限制、能耗约束和部署变化都可能导致模态缺失。现有研究主要从随机模态丢弃、共享-特定表示、缺失模态生成和完整到不完整知识迁移等方向展开 [11], [12], [25], [26]。

模态不变表示学习希望将不同模态组合映射到统一表示空间, 使模型能够处理可变数量的输入模态。X-Fi 通过模态专属编码器和跨模态融合支持多种传感器组合 [2]; 模态 dropout 则在训练阶段随机移除输入, 以提高推理时的缺失鲁棒性 [12]。前者强调统一模型的组合适应能力, 后者主要改变训练分布, 但二者都未直接规定完整观测行为应如何约束当前有限子集。

另一类方法通过共享潜空间或代理表示补全缺失模态。此类方法可以保持固定融合接口, 但对 LiDAR、毫米波雷达和 WiFi-CSI 等物理异构信号, 代理特征可能引入额外误差。专家网络和门控机制能够按输入条件选择分支, 却可能随传感器数量增加而提高结构与配置成本。VK-RMD 采用不同路线: 不生成不可观测模态, 而只组织当前可见 chunk 的任务证据。

知识蒸馏也被用于完整到不完整多模态学习。传统蒸馏及特征提示分别约束输出分布和中间表示 [27]–[29]; 不完整多模态方法进一步使用完整模态 teacher 指导部分模态 student [13], [14], [30]。这些工作说明完整观测能够作为训练期参考, 但没有形成本文面向 HPE/HAR 的任务响应、骨架结构、token 表示与可见融合分布联合约束。本文因此不把 teacher-student 形式本身作为创新, 而把贡献限定在任务化的一致性目标及其与动态证据读出的耦合。

C. 低视觉暴露人体感知

在隐私敏感环境中, 人体感知模型不仅需要保证任务性能, 还需要控制输入信号带来的视觉暴露。原始 RGB 图像包含面部、衣着、体型、背景和场景布局等信息, 即使下游任务只关注姿态或动作, 仍可能带来身份和环境泄露风险。因此, 近年来研究者开始探索使用低外观表示或非视觉传感器来替代在线 RGB 输入。




Fig. 1. VK-RMD 总体框架。在线原始 RGB 不进入下游模型；Visual Keypoints 经关节身份与骨拓扑编码形成低外观结构 token，异构传感器经模态专属编码器形成等维 token。完整观测 teacher 通过 SP-SFC 条件化指导随机子集 student，student 以 chunk 专家读出和全局融合 token 读出联合形成 HPE/HAR 预测。

骨架和关键点表示主要保留关节位置、拓扑和运动模式，减少纹理、颜色与背景信息；低分辨率视觉和可学习光学前端也被用于限制可识别外观 [31], [32]。与此同时，Depth、LiDAR、毫米波雷达和 WiFi-CSI 为减少在线 RGB 依赖提供了不同路径，但不同传感器仍可能保留身体几何、步态或环境相关线索。

因此，低视觉暴露并不等同于严格隐私保护。骨架关键点仍可能包含体型、步态和动作习惯，Depth 与 LiDAR 也可能反映人体形状和空间行为。本文采用可检验的较窄目标：排除在线下游原始 RGB，并以主体识别探针量化表示中的残余身份可预测性，而不声称匿名性或形式化隐私保证。低视觉暴露、动态模态可用性和跨协议迁移由此构成同一部署问题的三个边界，而不是三个互不相关的卖点。

III. VK-RMD: 可用性条件结构证据学习框架

本节从一个统一问题出发构建 VK-RMD：当原始 RGB 不进入在线感知模型、且传感器可用性随时间变化时，模型既要保留对 HPE/HAR 有效的人体结构，又要避免将完整观测下的融合规律机械复制到信息不完整的子集。为此，VK-RMD 将方法组织为三个相互依赖的机制：以 Visual Keypoints (VK) 建立低外观结构接口；以完整到子集的结构-融合一致性约束连接完整观测与随机子集；以可见 modality chunk 的双层证据读出处理子集变化引起的证据支配差异。图 1 给出了整体计算流程。

A. 问题定义与设计原则

令 $\mathcal{M}_{\text{HPE}} = \{v, d, l, r, w\}$ 和 $\mathcal{M}_{\text{HAR}} = \{v, d, l, r\}$ 分别表示 HPE 与 HAR 的候选模态集合，其中 v, d, l, r, w 依次表示 VK、Depth、LiDAR、毫米波雷达和 WiFi-CSI。同步样本本记为 $\mathcal{X} = \{x_m\}_{m \in \mathcal{M}}$ ，监督标签记为 y ；HPE 中 $y \in \mathbb{R}^{17 \times 3}$ ，HAR 中 $y \in \{1, \dots, C\}$ 。在线时模型只接收一个非空可见子集 $S \subseteq \mathcal{M}$ ，其输入为 $\mathcal{X}_S = \{x_m \mid m \in S\}$ ，并预测 $\hat{y}_S = F(\mathcal{X}_S, S)$ 。训练时，student 的 S 由模态丢弃分布 $q(S)$ 采样；当前实现从允许的缺失数量集合中等概率选择一个数量，再在候选模态中均匀选择被丢弃项。测试则枚举所有非空组合，从而将每个组合视为一种合法部署状态，而不把模态丢弃仅解释为普通正则化。

这一问题包含三个耦合矛盾。首先，去除在线 RGB 会削弱密集视觉外观，但人体结构仍需进入模型；其次，完整观测 teacher 与随机子集 student 的信息容量不同，直接复制完整融合分布并不合理；最后，不同子集中的主导模态会改变，单一全局读出可能掩盖弱但互补的可见证据。VK-RMD 的三个核心模块分别对应这三个矛盾，并由同一子集变量 S 贯穿编码、融合和训练目标。

B. VK 低外观结构接口

1) 关节身份与骨拓扑编码：VK 输入记为 $K \in \mathbb{R}^{17 \times 2}$ 。它是上游关键点模块输出的结构化接口，而不是在线原始图像。本文实验使用数据集中同步提供的 17 点 VK；上游如何产生 VK 不属于当前下游模型的优化范围，因此本文不假设不同来源的关键点具有相同精度。该边界使本文的声明限定为 raw-RGB-free online inference 和 reduced visual exposure，而不是形式化隐私保证。

对于不同坐标尺度，首先将有限坐标自适应归一到 $[0, 1]$ 并截断异常值，得到 $\tilde{K} = \text{Normalize}(K)$ 。第 j 个关节同时编码绝对位置、中心化位置和关节身份；随后依据 COCO-17 骨连接构造含自环、按节点度归一化的邻接矩阵 A 。整个 VK 结构编码可凝练为

$$\begin{aligned} H_{v,j}^{(0)} &= \phi_c(\tilde{K}_j) + \phi_p(2\tilde{K}_j - 1) + e_j^{\text{joint}}, \\ H_v^{(q+1)} &= \text{LN}\left(H_v^{(q)} + \psi_q[H_v^{(q)} \| AH_v^{(q)}]\right), \\ Z_v &= P_v(H_v^{(Q)}) \in \mathbb{R}^{K_t \times D}. \end{aligned} \quad (1)$$

其中 ϕ_c 与 ϕ_p 为多层感知机， e_j^{joint} 为可学习关节嵌入， ψ_q 为骨邻域混合映射。实现采用两层骨图混合，并将 17 个 joint tokens 投影为 $K_t = 32$ 个、维度为 $D = 512$ 的结构 token。该设计避免把坐标序列视为无语义点集：即使两个关节坐标接近，其 joint identity 仍然不同。因此，VK 的作用不是作为 attention query 查询其他传感器，也不是要求其他模态回归到二维关键点坐标；它提供的是一种保留关节身份和拓扑关系的低外观人体结构接口。

2) 与其他传感器的关系：Depth、LiDAR、毫米波雷达和 WiFi-CSI 在原始空间中分别表现为深度阵列、点云、雷达反射和信道状态序列，不存在统一的像素级对应关系。

对每个非 VK 模态 m , VK-RMD 使用与其数据结构匹配的预训练 backbone B_m 提取特征, 并冻结这些 backbone 以保留原有传感器表征; 随后使用可训练 projector 将输出变为固定数量的 token。这里统一的是 token 数量和特征维度, 而不是传感器的物理坐标。VK、非视觉传感器、同步样本和共同 HPE/HAR 标签共同诱导 task-supervised human-state tokenization; 本文不将这一过程表述为严格的 body-latent semantic alignment。

C. 可用性条件的 Human-State Tokenization

对当前可见模态加入模态身份嵌入, 并仅拼接当前存在的 token。异构传感器投影、子集编码与 chunk 恢复可概括为

$$\begin{aligned} Z_m &= P_m(B_m(x_m)), \quad \bar{Z}_m = Z_m + e_m, \\ T_S &= \text{TrEnc}(\text{Concat}_{m \in S} \bar{Z}_m) = [C_m]_{m \in S}, \end{aligned} \quad (2)$$

其中 $Z_m, C_m \in \mathbb{R}^{K_t \times D}$ 。实现中 Transformer 包含两层、八个注意力头, 能够接受由 $|S|$ 决定的可变 token 长度。Self-attention 只在当前可见证据之间建立依赖, 不构造零填充 token, 也不生成缺失模态代理。每个 C_m 已包含跨模态上下文, 但仍保留清晰的来源边界, 因而被称为 visible modality chunk。

D. 子集自适应的可见 Chunk 双层证据读出

1) *Chunk* 级任务证据: 对于每个 C_m , 共享任务头而非独立参数专家产生模态级预测 $\hat{y}_m$ 与标量 log-variance s_m 。HPE 中 $\hat{y}_m \in \mathbb{R}^{17 \times 3}$, HAR 中 $\hat{y}_m \in \mathbb{R}^C$ 。共享参数保证不同模态接受同一任务判据, 而 chunk 边界使每个可见模态在全局压缩前保留独立任务证据。因而, “chunk expert” 指按模态读取的任务证据, 而不是参数互不共享的 mixture-of-experts。

在默认 uncertainty 模式下, s_m 经温度化 softmax 形成当前子集内的 contribution proxy。局部预测、全局 token 及最终输出统一表示为

$$\begin{aligned} (\hat{y}_m, s_m) &= H_{\text{shared}}(C_m), \quad \alpha_m^S = \frac{e^{-s_m/\tau}}{\sum_{j \in S} e^{-s_j/\tau}}, \\ \hat{y}_{\text{chunk}}^S &= \sum_{m \in S} \alpha_m^S \hat{y}_m, \quad z_S = \sum_{m \in S} \alpha_m^S \text{Pool}(C_m), \\ \hat{y}_S &= \frac{1}{2} \hat{y}_{\text{chunk}}^S + \frac{1}{2} H_{\text{global}}(z_S). \end{aligned} \quad (3)$$

α_m^S 只反映当前任务、样本和模态组合下的相对贡献, 不代表经过校准的物理传感器可靠性。其数值由后述异方差任务损失学习, 而不是由人工质量标签指定。

2) 局部预测与全局 token 的耦合聚合: 式 (3) 包含两条耦合读出路径: 第一条直接聚合可见 chunks 的任务预测, 第二条使用同一组 α_m^S 聚合 pooled chunk tokens, 并由全局任务头读取子集级互补证据。该设计的关键并非简单并联两个 head, 而是同一 contribution proxy 同时控制预测级证据和 token 级证据: 局部路径保留可见模态的直接任务判断, 全局路径建模跨模态互补关系。全局头预测完整任务输出, 并非拟合局部路径的数值残差, 因此本文使用“全局 fused-token 读出”而非“残差修正”描述该分支。

E. 完整到子集的结构-融合一致性

1) 观测条件不对称的 Teacher-Student 训练: VK-RMD 先以完整模态集合 $\mathcal{M}$ 训练 teacher F_T , 再固定 teacher, 并训练与其容量近似的 student F_S 。二者的关键差异不是模型规模, 而是观测条件: teacher 计算 $O_T = F_T(\mathcal{X}_{\mathcal{M}}, \mathcal{M})$, student 则在 $S \sim q(S)$ 下计算 $O_S = F_S(\mathcal{X}_S, S)$ 。完整到不完整的 teacher-student 关系已有研究基础 [14], [27], [28]。本文的机制贡献是将其具体化为面向异构人体感知的结构-融合多层一致性体系, 并与上述可见 chunk 证据读出耦合。为与全文现有记号保持一致, 下文仍记为 SP-SFC; 其精确含义是 full-to-subset structural-fusion consistency, 而不是声称所有 teacher 表示均经过显式子集投影。

2) 当前子集上的融合行为约束: 完整 teacher 输出 $\alpha_T^{\mathcal{M}}$ 。直接要求 student 复制该分布既存在维数差异, 也忽略缺失模态的概率质量。因而, 只对融合行为执行可见子集限制并重新归一:

$$\tilde{\alpha}_{T,m}^S = \frac{\alpha_{T,m}^{\mathcal{M}}}{\sum_{j \in S} \alpha_{T,j}^{\mathcal{M}}}, \quad \mathcal{L}_{\text{rel}} = D_{\text{KL}}(\tilde{\alpha}_T^S \parallel \alpha_S). \quad (4)$$

式 (4) 对应实际实现中以 teacher 分布为 KL target 的方向。它监督的是“在相同可见证据条件下如何重新分配贡献”, 而不是要求 student 恢复不可观测模态。

3) 任务误差驱动的 Contribution Proxy: 每个可见 chunk 的 log-variance 由其独立任务误差监督:

$$\mathcal{L}_{\text{unc}} = \frac{1}{|S|} \sum_{m \in S} [\exp(-s_m) \ell_m + s_m], \quad (5)$$

其中 HPE 使用模态级 Smooth-L1 姿态误差, HAR 使用模态级交叉熵。由于 s_m 同时决定式 (3) 中的 α_m^S , 该目标把 chunk 预测质量与子集证据分配联系起来。需要注意, 代码并未单独最小化 teacher 与 student 的 log-variance 距离; teacher 的不确定性只通过 $\tilde{\alpha}_T^S$ 间接影响 student, 避免把未实现的 uncertainty distillation 写入方法。

F. 任务特定目标与总体优化

1) *Teacher* 目标: HPE teacher 使用真实姿态 Smooth-L1 回归和骨长约束, 即 $\mathcal{L}_T^{\text{HPE}} = \ell_{\text{SL1}}(\hat{p}_T, y) + \lambda_b \mathcal{L}_{\text{bone}}(\hat{p}_T, y)$ 。HAR teacher 使用真实类别交叉熵, 并以式 (5) 约束各 chunk 的分类证据, 即 $\mathcal{L}_T^{\text{HAR}} = \text{CE}(\hat{c}_T, y) + \lambda_u \mathcal{L}_{\text{mismatch}}^T$ 。

2) *HPE Student* 目标: HPE 的 ground-truth 项为 $\mathcal{L}_{\text{gt}} = \ell_{\text{SL1}}(\hat{p}_S, y)$, 输出一致性为 $\mathcal{L}_{\text{out}} = \ell_{\text{SL1}}(\hat{p}_S, \text{sg}(\hat{p}_T))$ 。令 q_S 与 q_T 表示编码 token 的全局均值, 则 $\mathcal{L}_{\text{tok}} = \|q_S - \text{sg}(q_T)\|_2^2$ 。骨结构项 $\mathcal{L}_{\text{bone}}$ 对 COCO-17 各骨段的 student/teacher 长度执行平均 L1 约束。完整 HPE student 目标为

$$\begin{aligned} \mathcal{L}_S^{\text{HPE}} &= \mathcal{L}_{\text{gt}} + \lambda_{\text{out}} \mathcal{L}_{\text{out}} + \lambda_{\text{tok}} \mathcal{L}_{\text{tok}} + \lambda_{\text{bone}} \mathcal{L}_{\text{bone}} \\ &\quad + \lambda_{\text{rel}} \mathcal{L}_{\text{rel}} + \lambda_{\text{unc}} \mathcal{L}_{\text{unc}}. \end{aligned} \quad (6)$$

其中 output、token 和 bone 项直接参照完整 teacher; 只有 $\mathcal{L}_{\text{rel}}$ 将 teacher 融合分布限制到 student 的当前可见子集。因此, SP-SFC 表示一个完整到子集的联合一致性体系, 而不是对每个 teacher 中间变量都执行同一种投影算子。

3) *HAR Student* 目标: HAR student 首先由真实标签监督 $\mathcal{L}_{\text{ce}} = \text{CE}(\hat{c}_S, y)$ 。soft-response 项 $\mathcal{L}_{\text{logit}}$ 使用温度 T_d 下 teacher 到 student 的 KL 散度, 并乘以 T_d^2 ; q_S 和 q_T 对应

contribution-weighted fused token, 其 token 一致性仍采用均方误差。总目标为

$$\mathcal{L}_S^{\text{HAR}} = \mathcal{L}_{\text{ce}} + \lambda_{\text{kd}} \mathcal{L}_{\text{logit}} + \lambda_{\text{tok}} \mathcal{L}_{\text{tok}} + \lambda_{\text{rel}} \mathcal{L}_{\text{rel}} + \lambda_{\text{unc}} \mathcal{L}_{\text{unc}}. \quad (7)$$

HPE 与 HAR 共享完整观测到随机子集的训练逻辑, 但根据几何回归和语义分类的任务性质使用不同结构项。这种任务化实例化比把所有任务统一为单一 logits 蒸馏更能对应人体感知中的几何与语义差异。

G. 训练与推理流程

完整流程可概括为以下步骤:

- 1) 使用完整模态样本训练 teacher, 并固定其参数;
- 2) 对每个 student batch 采样可见子集 $S \sim q(S)$, 只激活 S 中的编码器;
- 3) 将 VK 结构 token 和可见物理传感器 token 输入共享 Transformer, 并按来源恢复 visible chunks;
- 4) 由共享任务头生成 chunk 预测与 log-variance, 再以同一 contribution proxy 形成局部预测聚合和全局 fused-token 读出;
- 5) 使用真实标签、完整 teacher 的任务/表示/结构目标以及重归一化后的可见融合分布更新 student;
- 6) 推理时移除 teacher, student 直接接受任意非空模态组合并输出 HPE 或 HAR 结果。

上述计算链说明三项机制为何构成整体而非并列模块: VK 接口定义在线模型保留的人体信息; SP-SFC 定义完整与有限观测之间的训练关系; visible-chunk 双层读出定义当前子集中的证据组织方式。后续实验分别通过身份探针与 VK 配对边际贡献、teacher-guidance 与全子集分析、uniform fusion 和 chunk/global/dual 消融检验这三个机制假设, 并通过 cross-subject 与 cross-scene 协议报告其泛化边界。

IV. 实验设置

数据集与任务。本文在 MMFi 多模态人体感知数据集上训练和评估 VK-RMD。MMFi 提供同步采集的多模态人体感知数据, 包含 40 名受试者、27 类动作以及多种传感器模态。

对于人体姿态估计任务 (Human Pose Estimation, HPE), 本文使用 Visual Keypoints、Depth、LiDAR、毫米波雷达和 WiFi-CSI 五种输入模态, 并采用 17 个三维人体关节坐标作为监督标签。对于人体活动识别任务 (Human Activity Recognition, HAR), 本文使用 Visual Keypoints、Depth、LiDAR 和毫米波雷达四种输入模态, 并预测 27 类人体动作标签。与在线 RGB-based 方法不同, 本文不将原始 RGB 输入到下游 HPE/HAR 模型中, 而是使用 Visual Keypoints 作为低视觉暴露的人体结构输入。

为了全面评估模型在不同部署条件下的表现, 本文采用三类协议进行实验。第一类是 cross-random-split 协议, 用于评估模型在随机划分训练集和测试集条件下的整体性能。第二类是 cross-subject 协议, 用于评估模型对未知受试者的泛化能力。第三类是 cross-scene 协议, 用于评估模型在不同环境布设下的跨场景泛化能力。

此外, 本文对 HPE 和 HAR 分别进行全子集模态组合评估。对于 HPE, 五种模态共形成 31 种非空组合; 对于 HAR, 四种模态共形成 15 种非空组合。该设置用于模拟真实 IoT 场景中传感器随机缺失和动态可用的情况。

训练目标。VK-RMD 的训练包含完整模态 teacher 和随机缺失模态 student 两个阶段。Teacher 使用完整模态输入进行训练, 不执行随机模态丢弃, 用于学习所有传感器可用条件下的完整感知行为。Student 在训练阶段随机采样可用模态子集, 并在缺失模态条件下完成 HPE 或 HAR。二者构成 Full-to-Subset 训练关系, 具体约束由 SP-SFC 实现。

对于 HPE, teacher 的训练目标由姿态回归损失和骨架结构损失组成。Student 的训练目标包括真实姿态标签监督、teacher 姿态输出约束、body-token 约束、骨架结构约束、融合权重约束和不确定性约束。

对于 HAR, teacher 使用交叉熵损失和专家不确定性约束进行训练; student 的训练目标包括真实动作标签交叉熵、teacher soft logits 约束、body-token 约束、融合权重约束和不确定性约束。与传统模型压缩式蒸馏不同, 本文的训练目标并不是将大模型压缩为小模型, 而是使随机缺失模态 student 学习完整模态 teacher 的感知行为。

对比方法。本文主要与已有 X-Fi 结果进行对比。X-Fi 是面向模态不变人体感知的代表性方法, 能够处理不同模态组合的人体姿态估计和人体活动识别任务。为保证对比清晰, 本文采用 X-Fi 原论文中报告的 MMFi HPE 和 HAR 表格结果作为主要对照, 并在相同模态组合下报告 VK-RMD 的结果。

对于 HPE, 本文比较 MPJPE 和 PA-MPJPE 两个指标; 对于 HAR, 本文比较分类准确率。需要说明的是, 本文不使用复现过程中出现的异常 X-Fi 结果作为主对比, 而采用原论文表格中公开报告的数值作为基线。

除 X-Fi 外, 本文还设置若干内部消融和补充对比, 用于分析 VK-RMD 中不同组成部分的作用。包括完整模态 baseline、uniform fusion、无蒸馏约束变体、不同缺失强度下的 student 结果、Student-VK 与 Student-NV 结果, 以及 reliability-aware fusion 相关诊断实验。这些实验用于分析低视觉暴露输入、随机模态缺失训练、子集自适应融合和 SP-SFC 对整体性能的影响。

实现细节。本文对不同模态采用模态专属编码器, 并将其输出统一投影到 body-token 空间。每个模态被映射为 32 个 token, 每个 token 的维度为 512。Visual Keypoints 分支首先对 17 个关键点进行坐标归一化和关节级嵌入, 并结合骨架拓扑关系生成结构化人体 token。

Depth、LiDAR、毫米波雷达和 WiFi-CSI 分支分别采用对应的预训练传感器 backbone 提取模态特征, 并通过投影层映射到统一维度。跨模态 Transformer 使用 2 层编码器结构和 8 个注意力头, 用于建模不同模态 token 之间的交互关系。融合模块采用 chunk 级专家预测与全局融合 token 读出协同机制, 并根据不确定性估计生成子集贡献权重。

HPE 和 HAR 实验均使用 AdamW 优化器进行训练, batch size 设为 16。HPE 训练 100 个 epoch, HAR 训练 50 个 epoch。Student 训练时随机丢弃 1 到 3 个模态, 以模拟不同程度的传感器缺失。模型每隔固定 epoch 在验证集上评估, 并保存最佳 checkpoint。所有实验在 NVIDIA GPU 上完成。

对于全子集评估, 本文不再重新训练每一种模态组合, 而是使用训练好的 VK-RMD student 直接测试所有可用模态组合, 从而验证模型在动态传感器可用状态下的适应能力。通过上述设置, 本文能够同时评估 VK-RMD 在低视觉暴露输入、完整模态性能、随机缺失模态鲁棒性、跨主体泛化和跨场景泛化五个方面的表现。

V. 实验结果与分析

A. 与 X-Fi 的逐模态组合比较

本文首先按照 X-Fi 原论文的模态组合顺序报告 HPE 和 HAR 结果，而不以单一平均值代替不同传感器状态。需要强调的是，X-Fi 表中的视觉模态为 RGB，而 VK-RMD 使用 Visual Keypoints；因此，含视觉模态的行用于说明两种部署路线在公开表项下的性能差异，不能解释为输入完全相同的严格公平比较。由 Depth、LiDAR、毫米波雷达和 WiFi-CSI 构成的纯非视觉行具有一致的传感器输入，是更直接的输入匹配比较。两类表项均采用 MMFi 的公开协议与相同任务指标。

TABLE I

MMFi HPE 逐模态组合比较 (mm, 数值越低越好)。V 在 X-Fi/VK-RMD 中分别表示 RGB/VK；D、L、R、W 分别表示 DEPTH、LiDAR、mmWave、WiFi-CSI。绿色和红色分别表示提升和退化。

模态	MPJPE↓			PA-MPJPE↓		
	X-Fi	VK-RMD	Δ	X-Fi	VK-RMD	Δ
V	93.9	92.7	↓ 1.2	60.3	42.6	↓ 17.7
D	101.8	53.9	↓ 47.9	48.4	35.6	↓ 12.8
L	167.1	140.1	↓ 27.0	103.2	93.5	↓ 9.7
R	127.4	115.0	↓ 12.4	69.8	58.1	↓ 11.7
W	225.6	222.1	↓ 3.5	105.3	110.2	↑ 4.9
V+D	86.1	51.7	↓ 34.4	48.1	34.3	↓ 13.8
V+L	93.0	73.2	↓ 19.8	59.7	41.9	↓ 17.8
V+R	88.8	68.9	↓ 19.9	57.3	38.9	↓ 18.4
V+W	93.0	88.1	↓ 4.9	59.5	42.3	↓ 17.2
D+L	102.5	53.0	↓ 49.5	48.4	35.4	↓ 13.0
D+R	98.0	52.3	↓ 45.7	47.3	34.6	↓ 12.7
D+W	101.8	53.5	↓ 48.3	48.1	35.5	↓ 12.6
L+R	109.8	97.5	↓ 12.3	63.4	55.1	↓ 8.3
L+W	159.5	134.2	↓ 25.3	102.7	93.2	↓ 9.5
R+W	117.2	108.5	↓ 8.7	62.7	57.3	↓ 5.4
V+D+L	84.8	51.1	↓ 33.7	48.2	34.2	↓ 14.0
V+D+R	83.4	50.5	↓ 32.9	47.3	33.5	↓ 13.8
V+D+W	85.3	51.6	↓ 33.7	48.1	34.3	↓ 13.8
V+L+R	88.4	66.1	↓ 22.3	57.2	38.8	↓ 18.4
V+L+W	93.0	70.7	↓ 22.3	59.7	41.8	↓ 17.9
V+R+W	88.5	66.7	↓ 21.8	57.1	38.8	↓ 18.3
D+L+R	96.0	51.9	↓ 44.1	47.3	34.5	↓ 12.8
D+L+W	102.0	52.9	↓ 49.1	48.1	35.4	↓ 12.7
D+R+W	97.0	52.1	↓ 44.9	47.1	34.6	↓ 12.5
L+R+W	107.4	94.2	↓ 13.2	63.1	55.1	↓ 8.0
V+D+L+R	83.5	50.2	↓ 33.3	47.6	33.4	↓ 14.2
V+D+L+W	86.0	51.0	↓ 35.0	48.2	34.2	↓ 14.0
V+D+R+W	84.0	50.4	↓ 33.6	47.6	33.5	↓ 14.1
V+L+R+W	88.6	64.2	↓ 24.4	57.1	38.8	↓ 18.3
D+L+R+W	97.6	51.8	↓ 45.8	47.4	34.5	↓ 12.9
V+D+L+R+W	83.7	50.2	↓ 33.5	47.6	33.5	↓ 14.1

人体姿态估计。表 I 显示，VK-RMD 在完整模态设置下将 MPJPE 从 83.7 mm 降至 50.2 mm，将 PA-MPJPE 从 47.6 mm 降至 33.5 mm。纯非视觉组合中，Depth 及其组合带来最稳定的几何约束，例如 D+L、D+R 和 D+W 的 MPJPE 分别为 53.0、52.3 和 53.5 mm，均明显低于对应 X-Fi 表项。LiDAR、毫米波雷达和 WiFi-CSI 单独输入时仍较困难，其中 WiFi-CSI 的 PA-MPJPE 从 105.3 mm 上升到 110.2 mm，说明本文并未在所有单模态状态下占优。总体结果支持的是多模态互补和动态子集适应，而不是每个传感器都成为强姿态模态。

人体活动识别。

TABLE II

MMFi HAR 逐模态组合比较 (ACCURACY, %)。V 在 X-Fi/VK-RMD 中分别表示 RGB/VK；D、L、R 分别表示 DEPTH、LiDAR、mmWave。绿色和红色分别表示提升和退化。

模态	X-Fi Acc.↑	VK-RMD Acc.↑	Δ Acc.
V	26.5	65.3	↑ 38.8
D	48.1	88.0	↑ 39.9
L	52.7	40.8	↓ 11.9
R	85.7	85.9	↑ 0.2
V+D	45.3	89.5	↑ 44.2
V+L	35.2	68.5	↑ 33.3
V+R	73.4	92.7	↑ 19.3
D+L	51.6	88.5	↑ 36.9
D+R	79.8	96.4	↑ 16.6
L+R	88.7	89.5	↑ 0.8
V+D+L	48.7	89.6	↑ 40.9
V+D+R	70.7	96.6	↑ 25.9
V+L+R	77.8	92.7	↑ 14.9
D+L+R	80.5	96.4	↑ 15.9
V+D+L+R	72.2	96.6	↑ 24.4

表 II 显示，完整模态 Accuracy 从 72.2% 提升至 96.6%。在输入匹配的纯非视觉组合中，D、R、D+L、D+R、L+R 和 D+L+R 均优于 X-Fi，但 LiDAR 单模态由 52.7% 降至 40.8%。这表明 HAR 更依赖 Depth 的几何变化和毫米波雷达的运动反射，而稀疏 LiDAR 单独使用时难以稳定区分动作。HPE 与 HAR 的差异也说明，VK-RMD 学习的是任务相关模态贡献，而非固定的全局模态排序。

B. Visual Keypoints 的结构效用与低视觉暴露证据

逐组合表中的含 V 行同时改变了视觉表示，不能单独回答 VK 是否为同一模型提供增量信息。为此，本文执行配对边分析：对每个不含 VK 的传感器子集 S ，在同一已训练 student 内比较 S 与 $S + V$ ，使配对内唯一变化为是否加入 VK。

TABLE III

VISUAL KEYPOINTS 的配对边贡献。正增益始终表示加入 VK 后任务性能改善；HPE 的增益为误差降低量，HAR 的增益为百分点提升。符号一致性仅作描述性统计，因为不同子集共享模型参数与传感器。

任务	指标	配对数	改善数	改善比例	平均增益	中位增益
HPE	MPJPE	15	15	100%	28.56 mm	2.22 mm
HPE	PA-MPJPE	15	15	100%	16.70 mm	1.31 mm
HAR	Accuracy	7	7	100%	5.81 pp	1.49 pp
HAR	Macro-F1	7	7	100%	5.97 pp	1.51 pp

表 III 显示，加入 VK 后，HPE 的 15 个匹配子集和 HAR 的 7 个匹配子集均得到改善。平均增益明显大于中位增益，说明 VK 对部分弱非视觉子集的补充尤其突出，而在已有强物理证据时增益较小。该结果证明 VK 具有条件任务价值，但不支持“VK 是唯一中心模态”的表述；后文 leave-one-out 结果显示，HPE 和 HAR 仍分别高度依赖 Depth 和毫米波雷达。

TABLE IV

不同输入表示的主体身份线性探测结果。ACCURACY 越低表示该探针从输入中恢复主体身份越困难，但不等价于形式化隐私保证。

输入表示	Accuracy	主要残余线索
随机猜测	2.50%	40 个主体
脱敏 RGB	67.53%	体型、服饰与背景
Visual Keypoints	15.43%	身体几何与动作
Depth	43.80%	几何外形
LiDAR	36.57%	体形与运动
mmWave	9.72%	动态反射
WiFi-CSI	8.65%	信道扰动

表 IV 中, VK 的主体识别率为 15.43%, 显著低于脱敏 RGB 的 67.53%, 但仍高于 2.50% 的随机水平。因此, VK 的作用是抑制面部、衣着、纹理和背景等外观信息, 同时保留人体几何; 它降低而非消除身份泄露。Depth 和 LiDAR 仍具有较高身份可预测性, 也说明“非 RGB”不能自动等同于隐私安全。本文据此仅使用低视觉暴露和 privacy-friendly 表述, 不作匿名性、差分隐私或密码学安全承诺。

C. 随机缺失模态鲁棒性

TABLE V

按缺失模态数量分组的全子集结果。HPE 为 MPJPE/PA-MPJPE, 单位 mm, 越低越好; HAR 为 ACCURACY/F1, 单位%, 越高越好。VK 表示 STUDENT-VK, NV 表示完全非视觉 STUDENT-NV。

缺失数量	HPE↓				HAR↑			
	VK MPJPE	VK PA	NV MPJPE	NV PA	VK Acc.	VK F1	NV Acc.	NV F1
0	50.2	33.5	51.0	35.7	96.6	96.5	96.1	96.1
1	53.5	34.9	61.3	40.5	93.8	93.8	90.1	90.0
2	60.8	38.1	79.4	50.7	87.5	87.6	66.0	65.7
3	78.1	46.8	124.3	71.2	70.0	69.9	—	—
4	124.8	68.0	—	—	—	—	—	—

表 V 显示, 性能随缺失程度增加而有序退化, 而不是在任一模态离线后立即失效。HPE 中, Student-VK 从完整模态的 50.2 mm 增至仅保留单模态时的平均 124.8 mm; 对应 Student-NV 从 51.0 mm 增至 124.3 mm。HAR 中, Student-VK 在缺失一个和两个模态时仍达到 93.8% 和 87.5%, 而 Student-NV 在只剩单模态时下降到 66.0%。这些数据说明 VK 的价值主要出现在严重缺失和弱非视觉子集, 而完整强模态组合可以更多依赖物理传感器证据。

TABLE VI

LEAVE-ONE-OUT 关键模态分析。HPE 数值为移除对应模态后的误差增加量; HAR 数值为 ACCURACY/F1 下降量。V=VK, D=DEPTH, L=LiDAR, R=mmWave, W=WiFi-CSI。

移除模态	Δ MPJPE	Δ PA	Δ Acc.	Δ F1
V	1.6	1.1	0.1	0.1
D	14.1	5.3	3.8	3.7
L	0.2	0.1	0.0	0.0
R	0.9	0.7	6.9	7.1
W	0.1	-0.0	—	—

Leave-one-out 与配对边际分析回答了不同问题。表 VI 从完整强模态状态出发, 因而冗余较高: 移除 VK 只使 MPJPE 增加 1.6 mm, 而移除 Depth 增加 14.1 mm; HAR 中移除毫米波雷达使 Accuracy 下降 6.9 个百分点。这不否定 VK, 而是说明在完整观测时强物理模态能够替代部分结构信息; 表 III 则说明在相同非视觉子集上加入 VK 始

终有益。二者共同支持“结构接口与任务相关物理证据互补”, 而非“单一 VK 主导所有决策”。

D. 跨协议泛化与近期方法比较

TABLE VII

跨协议泛化结果。Avg. 表示所有非空模态子集的算术平均, Full 表示对应模型全部候选模态均可用; HPE 为 MPJPE (mm), HAR 为 ACCURACY (%)。

协议	模型	HPE Avg.↓	HPE Full↓	HAR Avg.↑	HAR Full↑
random split	VK-RMD VK	75.18	50.17	85.15	96.56
random split	VK-RMD NV	84.68	51.03	80.62	96.12
cross-subject	VK-RMD VK	78.57	49.88	85.30	96.12
cross-subject	VK-RMD NV	90.74	52.45	81.26	95.70
cross-scene	VK-RMD VK	142.02	71.71	80.61	95.25
cross-scene	VK-RMD NV	153.89	78.96	76.70	95.41

TABLE VIII

与近期 MMF1 缺失模态方法的协议级比较。仅统计共同的纯非视觉子集; 公开论文未提供相同逐样本清单, 因此该表不是同代码复现。

任务/指标	方法	VK-RMD 更优
HPE/MPJPE	PTA [33]	4/7
HPE/PA-MPJPE	PTA [33]	5/7
HAR/Accuracy	COMPASS [34]	5/7

TABLE IX

RANDOM SPLIT 下的核心消融。Avg. 为全组合平均, Full 为完整候选模态输入; HPE 报告 MPJPE (mm), HAR 报告 ACCURACY (%)。

任务	设置	全组合平均	完整模态
HPE	VK-RMD	75.18	50.17
HPE	w/o SP-SFC	72.68	48.83
HPE	uniform fusion	82.77	52.28
HAR	VK-RMD	85.15	96.56
HAR	w/o SP-SFC	82.86	95.99
HAR	uniform fusion	67.46	95.39

表 VII 显示, cross-subject 与 random split 的差距有限, 说明模型能够适应未见主体; 但 cross-scene HPE 的平均 MPJPE 从 75.18 mm 上升到 142.02 mm, Student-NV 也从 84.68 mm 上升到 153.89 mm。HAR 的跨场景退化相对较小, 但仍可观察到全子集平均下降。由此可见, 缺失模态鲁棒性与跨场景鲁棒性是两个不同问题: 随机子集训练缓解传感器可用性变化, 却没有消除环境布设、空间反射和无线传播分布偏移。

PTA 比较覆盖 Depth、LiDAR 与 WiFi-CSI 的 7 个共同非空子集, COMPASS 比较覆盖 Depth、LiDAR 与毫米波雷达的 7 个共同非空子集; 所有包含 RGB 或 VK 的表项均被排除。表 VIII 表明 VK-RMD 在多数共同子集上具有竞争力, 但并非全面胜出, LiDAR 单模态和部分 LiDAR 主导组合仍是弱点。由于公开工作未提供相同逐样本清单, 该结果只能称为协议级比较, 不能替代同代码、同预算的 adapted baseline。

E. 机制消融与诊断边界

表 IX 中, uniform fusion 在 HPE 和 HAR 的全组合平均上分别退化 7.59 mm 和 17.69 个百分点, 说明按当前子集学习模态贡献比固定平均更适合缺失模态场景。SP-SFC

的收益具有任务依赖性: HAR 移除该约束后平均 Accuracy 下降 2.29 个百分点, 但 HPE 的 w/o SP-SFC 反而降低 2.50 mm。因此, 本文不把完整到子集监督宣称为两个任务上均成立的独立增益, 而将其定位为组织任务响应、结构 token 与融合行为的一致性约束; HPE 中如何避免 teacher 偏差仍需进一步研究。

TABLE X
相同 10-EPOCH 轻量预算下的读出路径消融。HPE 报告全组合平均 MPJPE/PA-MPJPE (mm, 越低越好); HAR 报告 ACCURACY/MACRO-F1 (% , 越高越好)。

任务	Readout	主指标	次指标
HPE	chunk-only	95.27	62.46
HPE	global-only	109.81	78.49
HPE	dual	99.44	68.00
HAR	chunk-only	80.57	36.67
HAR	global-only	81.41	38.17
HAR	dual	82.43	43.40

表 X 显示, 读出路径的作用具有任务依赖性: HPE 的 chunk-only 获得最低误差, 说明细粒度姿态回归更依赖保留模态来源的局部几何证据; HAR 的 dual 在 Accuracy 和 Macro-F1 上均最高, 说明动作分类受益于局部专家证据与全局跨模态语义的联合读取。因而, dual 不是所有任务上的单调最优分支, 而是为 HPE/HAR 提供统一读出接口; 该结果也限定了本文对双层读出的主张。

扰动与专家补偿诊断提供了进一步边界。破坏 VK 的关节顺序会降低部分 VK+Depth 和 VK+mmWave 组合的 HAR, 说明网络使用了关节身份而非仅统计坐标分布; 当非视觉强模态存在时, 最终融合预测通常优于受扰动的 VK 专家, 表明存在一定互补补偿。然而, VK 权重并未对所有噪声强度呈单调下降, 权重与专家质量的相关性也不稳定。因此, α_m 只能解释为训练得到的任务贡献代理, 不能称为经过校准的物理传感器可靠性。

F 部署成本与非视觉 VK 来源诊断

TABLE XI
代表性推理成本。延迟在 NVIDIA L40 GPU、BATCH SIZE 1 下测量; 参数量和模型大小不随激活模态子集改变。

任务	模态	参数量	模型大小	延迟
HPE	V	45.94M	175.39 MB	8.0 ms
HPE	V+D	45.94M	175.39 MB	21.4 ms
HPE	V+D+L+R+W	45.94M	175.39 MB	3375.7 ms
HAR	V	24.38M	93.06 MB	15.9 ms
HAR	V+D	24.38M	93.06 MB	36.0 ms
HAR	V+D+L+R	24.38M	93.06 MB	3321.3 ms

TABLE XII
非视觉来源 VK 的生成质量。指标与同步 17 点关键点标签比较, 仅用于来源可行性诊断。

来源	协议	MAE/pixel	NME	PCK@0.10
Depth	random	16.41	0.0813	79.79%
Depth	cross-subject	18.14	0.0843	79.00%
Depth	cross-scene	46.45	0.2538	3.71%
mmWave-temporal	cross-subject	19.14	0.0885	71.60%
mmWave-temporal	cross-scene	22.03	0.1163	53.30%

表 XI 显示, V 和 V+D 的轻量组合具有毫秒级延迟, 而包含点云与雷达处理的完整组合超过 3 s。因此, 模型参数量不随输入子集改变, 但实际延迟主要由被激活的传感器 backbone 决定; 全模态并不必然是实时部署的最佳选择。表 XII 考察结构接口的来源可扩展性。Depth-to-VK 在 random 与 cross-subject 下达到约 0.08 NME, 但 cross-scene 恶化到 0.2538; 时序 mmWave-to-VK 在 cross-subject 和 cross-scene 下分别为 0.0885 和 0.1163 NME。这些结果仅说明低外观传感器生成统一 17 点接口具有初步可行性, 同时揭示明显的来源域偏移; 它们不是主模型性能证明, 也不能支持“任意设备生成的 VK 可无损替代当前 VK”。

综上, 核心结果形成一条闭合证据链: 逐组合比较验证动态输入下的任务性能; 配对边际分析与身份探针分别验证 VK 的条件效用和低外观属性; 缺失强度、leave-one-out 与跨协议结果揭示鲁棒性来源及边界; uniform fusion 消融支持子集自适应贡献建模, 而 SP-SFC 的任务依赖结果和非单调权重响应则限定了机制主张。

VI. 讨论

创新边界。VK-RMD 的贡献不是分别发明 Visual Key-points、Transformer、modality dropout 或知识蒸馏。已有 X-Fi 已处理动态模态人体感知, 完整模态教师指导不完整模态网络也已有系统研究 [2], [13], [14]。本文的增量在于围绕同一科学矛盾建立三层机制关系: 首先, 以带有关节身份和骨拓扑的 VK 形成低外观结构接口; 其次, 以 SP-SFC 将完整观测教师的任务响应、结构、token 和融合分布条件化到学生当前可见子集; 最后, 以同一任务不确定性代理耦合 chunk 专家证据和全局融合 token 读出。该定位属于面向缺失传感器人体感知的机制与系统组合创新, 而不是新蒸馏理论或形式化隐私方法。

SP-SFC 的任务相关性。表 IX 显示, 移除蒸馏项后 HPE 平均 MPJPE 从 75.18 mm 改善至 72.68 mm, 而 HAR 平均 Accuracy 从 85.15% 降至 82.86%。这意味着完整到子集的一致性约束不是两个任务上的单调增益来源。HPE 的连续几何标签已经提供较强监督, 多层教师约束可能限制学生对特定子集的适应; HAR 的类别关系与完整观测响应则提供了更明显的辅助信息。因此, 本文将 SP-SFC 定位为任务相关的完整观测行为正则, 而把随机子集训练和子集自适应融合视为更稳定的鲁棒性来源。后续工作需要进一步研究任务自适应损失权重, 而不是默认更多蒸馏项必然更优。

贡献权重的解释。式 (3) 中的 α_m 来自专家预测 log-variance, 并随当前子集变化。Uniform fusion 的明显退化证明这种自适应证据分配具有任务价值, 但合成扰动实验中并非每个受扰模态的权重都单调下降。因此, α_m 应被解释为 learned contribution proxy, 而不是经过校准的物理传感器可靠性。同样, 统一 token 维度和共同任务监督只能说明模型学习了人体状态相关表示, 不能证明不同模态在严格数学意义上与 VK 完全对齐。

隐私与部署边界。主体识别探针量化了不同表示中的身份可预测性, 但不是完整的隐私攻击评估。VK 将识别准确率从脱敏 RGB 的 67.53% 降至 15.43%, 支持“降低身份与视觉暴露”; 然而 VK 仍高于随机水平, Depth 和 LiDAR 也保留显著身份线索。因此, 本文不声称匿名、差分隐私或密码学安全。另一方面, cross-scene HPE 平均 MPJPE 达到 142.02 mm, 明显弱于 random split 的 75.18 mm, 说明

缺失模态鲁棒性不能替代环境域泛化。当前系统更适用于固定或经过校准的传感器布设，跨环境自适应仍是重要后续方向。

实验限制。本研究主要在 MMFi 单一数据集上完成，核心模型尚缺少大规模多随机种子统计；X-Fi 原论文对比和 PTA/COMPASS 比较也不等于相同逐样本 manifest、输入表示与训练预算下的 adapted reproduction。此外，当前部署表只反映 L40 GPU 推理成本，不代表边缘设备能耗。读出路径消融已经揭示 HPE 与 HAR 对局部/全局证据的不同需求，但仍属于 10-epoch 轻量预算；未来需要在完整训练预算和多随机种子下复核该趋势，并在相同 VK 输入、相同子集序列和相同训练预算下复现 adapted X-Fi 与不完整多模态蒸馏方法。

VII. 结论

本文研究在线原始 RGB 不参与下游推理且传感器可能任意缺失条件下的多模态人体感知问题，并提出 VK-RMD。该方法以关节身份和骨拓扑编码 Visual Keypoints，形成低外观人体结构接口；以 SP-SFC 将完整观测教师的任务响应、结构、token 表示与融合行为投影到学生当前可见子集；并以任务不确定性代理联合组织 chunk 级专家证据和全局融合 token 表示。MMFi 上的 HPE 31 组合和 HAR 15 组合实验表明，VK-RMD 在完整输入和多种缺失条件下均保持竞争力。严格配对分析进一步显示，在控制非 VK 传感器子集不变后，加入 VK 在 HPE 15/15 与 HAR 7/7 配对中均改善任务性能；身份探针则表明 VK 显著降低但未消除主体可预测性。Uniform fusion、Student-NV 以及跨主体/跨场景实验共同说明，该框架的主要价值是低外观结构证据与动态传感器证据的协同组织，而不是依赖单一中心模态。同时，HPE 中任务相关的蒸馏收益、跨场景退化和残余身份泄露界定了当前方法的适用范围。总体而言，VK-RMD 为动态传感器可用条件下的低视觉暴露 HPE/HAR 提供了一条可追溯、可消融且边界明确的技术路径。

致谢

作者感谢 MMFi 与 X-Fi 工作提供公开数据、协议和基准实现。

数据与代码可用性

本文实验使用公开 MMFi 数据集。训练配置、评估脚本、全模态组合结果及生成论文表格所需的汇总文件将在论文发表时随项目仓库公开；涉及数据访问的部分遵循 MMFi 原始许可协议。

REFERENCES

- [1] J. Yang, H. Huang, Y. Zhou, X. Chen, Y. Xu, S. Yuan, H. Zou, C. X. Lu, and L. Xie, "MM-Fi: Multi-modal non-intrusive 4d human dataset for versatile wireless sensing," in *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [2] X. Chen and J. Yang, "X-Fi: A modality-invariant foundation model for multimodal human sensing," in *International Conference on Learning Representations*, 2025.
- [3] Y. Zhou, H. Huang, S. Yuan, H. Zou, L. Xie, and J. Yang, "MetaFi++: Wifi-enabled transformer-based human pose estimation for metaverse avatar simulation," *IEEE Internet of Things Journal*, vol. 10, no. 16, pp. 14 128–14 136, 2023.
- [4] Z. Cao, G. Mei, X. Guo, and G. Wang, "VirTeach: mmwave radar point-cloud-based pose estimation with virtual data as a teacher," *IEEE Internet of Things Journal*, vol. 11, no. 10, pp. 17 615–17 628, 2024.
- [5] Y. Zhou, J. Yang, H. Huang, and L. Xie, "AdaPose: Toward cross-site device-free human pose estimation with commodity wifi," *IEEE Internet of Things Journal*, vol. 11, no. 24, pp. 40 255–40 267, 2024.
- [6] X. H. Nguyen, V.-D. Nguyen, Q.-T. Luu, T. D. Gian, and O.-S. Shin, "Robust wifi sensing-based human pose estimation using denoising autoencoder and CNN with dynamic subcarrier attention," *IEEE Internet of Things Journal*, vol. 12, no. 11, pp. 17 066–17 079, 2025.
- [7] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "OpenPose: Realtime multi-person 2d pose estimation using part affinity fields," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 1, pp. 172–186, 2021.
- [8] K. Sun, B. Xiao, D. Liu, and J. Wang, "Deep high-resolution representation learning for human pose estimation," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019.
- [9] Y. Xu, J. Zhang, Q. Zhang, and D. Tao, "ViTPose: Simple vision transformer baselines for human pose estimation," in *Advances in Neural Information Processing Systems*, 2022.
- [10] S. Yan, Y. Xiong, and D. Lin, "Spatial temporal graph convolutional networks for skeleton-based action recognition," in *AAAI Conference on Artificial Intelligence*, 2018.
- [11] S. Woo, S. Lee, Y. Park, M. A. Nugroho, and C. Kim, "Towards good practices for missing modality robust action recognition," in *AAAI Conference on Artificial Intelligence*, vol. 37, no. 3, 2023, pp. 2776–2784.
- [12] N. Neverova, C. Wolf, G. Taylor, and F. Nebout, "ModDrop: Adaptive multi-modal gesture recognition," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 8, pp. 1692–1706, 2016.
- [13] Q. Wang, L. Zhan, P. Thompson, and J. Zhou, "Multimodal learning with incomplete modalities by knowledge distillation," in *ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2020, pp. 1828–1838.
- [14] S. Wei, C. Luo, and Y. Luo, "MMANet: Margin-aware distillation and modality-aware regularization for incomplete multimodal learning," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 20 039–20 049.
- [15] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, 2017.
- [16] J. Shotton, A. Fitzgibbon, M. Cook, T. Sharp, M. Finocchio, R. Moore, A. Kipman, and A. Blake, "Real-time human pose recognition in parts from single depth images," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2011.
- [17] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep learning on point sets for 3d classification and segmentation," in *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.
- [18] H. Zhao, L. Jiang, J. Jia, P. H. S. Torr, and V. Koltun, "Point transformer," in *IEEE/CVF International Conference on Computer Vision*, 2021.
- [19] M. Zhao, T. Li, M. A. Alsheikh, Y. Tian, H. Zhao, A. Torralba, and D. Katabi, "Through-wall human pose estimation using radio signals," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp. 7356–7365.
- [20] Y. Ma, G. Zhou, and S. Wang, "Wifi sensing with channel state information: A survey," *ACM Computing Surveys*, vol. 52, no. 3, pp. 1–36, 2019.
- [21] F. Wang, J. Liu, and W. Gong, "Wifi-based human activity recognition: A survey," *IEEE Communications Surveys and Tutorials*, vol. 21, no. 3, pp. 2879–2910, 2019.
- [22] D. Lahat, T. Adali, and C. Jutten, "Multimodal data fusion: An overview of methods, challenges, and prospects," *Proceedings of the IEEE*, vol. 103, no. 9, pp. 1449–1477, 2015.
- [23] Q.-S. Hong and C.-H. Lu, "Multimodal human activity recognition using contrastive fusion learning and lightweight isomorphic encoder for iot-enabled smart homes," *IEEE Internet of Things Journal*, vol. 12, no. 15, pp. 31 932–31 944, 2025.
- [24] M. G. Moghaddam, A. A. N. Shirehjini, and S. Shirmohammadi, "Device-free human activity recognition: A systematic literature review," *IEEE Open Journal of Instrumentation and Measurement*, vol. 4, pp. 1–34, 2025.
- [25] R. Wu, H. Wang, H.-T. Chen, and G. Carneiro, "Deep multimodal learning with missing modality: A survey," *Transactions on Machine Learning Research*, 2026.
- [26] H. Wang, Y. Chen, C. Ma, J. Avery, L. Hull, and G. Carneiro, "Multi-modal learning with missing modality via shared-specific feature modelling," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 15 878–15 887.

- [27] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” arXiv preprint arXiv:1503.02531, 2015.
- [28] A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, and Y. Bengio, “FitNets: Hints for thin deep nets,” in *International Conference on Learning Representations*, 2015.
- [29] V. Vapnik and A. Vashist, “A new learning paradigm: Learning using privileged information,” *Neural Networks*, vol. 22, no. 5–6, pp. 544–557, 2009.
- [30] H. Wang, C. Ma, J. Zhang, Y. Zhang, J. Avery, L. Hull, and G. Carneiro, “Learnable cross-modal knowledge distillation for multi-modal learning with missing modality,” in *Medical Image Computing and Computer Assisted Intervention*, 2023, pp. 216–226.
- [31] M. S. Ryoo, B. Rothrock, C. Fleming, and H. J. Yang, “Privacy-preserving human activity recognition from extreme low resolution,” in *AAAI Conference on Artificial Intelligence*, 2017.
- [32] C. Hinojosa, J. C. Niebles, and H. Arguello, “Learning privacy-preserving optics for human pose estimation,” in *IEEE/CVF International Conference on Computer Vision*, 2021.
- [33] P. Weng, Y. Qian, Y. Xu, and F. Wang, “Purify-then-align: Towards robust human sensing under modality missing with knowledge distillation from noisy multimodal teacher,” arXiv preprint arXiv:2604.05584, 2026.
- [34] H. Wang, Y. Qian, P. Weng, Z. Xia, W. Dan, Y. Xu, and F. Wang, “COMPASS: Complete multimodal fusion via proxy tokens and shared spaces for ubiquitous sensing,” arXiv preprint arXiv:2604.02056, 2026.